

ТЕСТОВОЕ ЗАДАНИЕ · АРХИТЕКТУРНЫЙ ТРЕК

# Система аналитики живых разговоров в дилерском центре

Проектирование системы целиком: захват звука в шоуруме, разбор разговоров, доведение результата до CRM и руководителя отдела продаж; второй этап — подсказки менеджеру в реальном времени

Автор: Илья

5 площадок · 100 менеджеров · горизонт 1000

Бюджет:  $\leq \$100$  CAPEX и  $\leq \$15/\text{мес}$  OPEX на менеджера

Все цены проверены по открытым источникам, август 2026 · курс 83 ₽/\$

Расчётная модель и работающий PoC пайплайна:

**[github.com/dadgrand/dealer-voice-analytics](https://github.com/dadgrand/dealer-voice-analytics)**

## Резюме решения

**Как это устроено.** Каждый менеджер носит бейдж-рекордер собственной разработки (ESP32-S3, два MEMS-микрофона, microSD, Opus-кодирование на борту; BOM  $\approx$  \$52 при тираже 100 шт и  $\approx$  \$31 при 1000 шт). Бейдж пишет звук всю смену и ни о чём не просит менеджера: снял с док-станции — запись пошла, поставил обратно — данные выгрузились, устройство заряжается. Близко расположенный микрофон решает сразу две главные проблемы шумного шоурума — отношение сигнал/шум и разделение голосов: голос менеджера всегда доминирует в его собственном бейдже, поэтому роли «менеджер/клиент» определяются по асимметрии каналов, а не по хрупкой слепой диаризации. На каждой площадке стоит свой шлюз (мини-ПК с собственной Wi-Fi-точкой и LTE-каналом) — система *вообще не зависит* от Wi-Fi дилера. Обработка — в российском облаке (требование 152-ФЗ): распознавание открытой моделью GigaAM-v3, дочистка диаризации ruannote, LLM-разбор каждого разговора в структурированный JSON (этапы, возражения, чек-лист), результат — карточкой в самописной CRM и дашбордом для РОПа.

**Сколько это стоит.** CAPEX — **\$98 на менеджера** при 100 менеджерах (бейдж \$52 + ЗИП + док + доля шлюза) и **\$75** при 1000 — в бюджете \$100. OPEX — **\$11.7/мес** на менеджера при 100 и **\$8.9** при 1000 в консервативном сценарии (при оптимистичных, но реалистичных допущениях — \$7.4 и \$3.7) — в бюджете \$15 с запасом. Ключевые решения, которые удерживают экономику: self-hosted ASR вместо облачных API распознавания (те стоили бы  $\sim$ \$28/мес на менеджера — вдвое больше всего бюджета), аренда GPU класса RTX 4090 в РФ от 40–83 ₽/час и LLM-разбор ночным батчем на тех же GPU.

**Почему это будет полезно.** РОП впервые видит, что происходит в разговорах: какие возражения системно не отрабатываются, на каком этапе теряются сделки, кого чему учить — не по самоотчётам менеджеров, а по фактическим диалогам. При марже дилера 50–150 тыс. ₽ с автомобиля системе достаточно приносить площадке *один* дополнительный проданный автомобиль раз в четыре месяца, чтобы окупаться; реалистичная цель — +1–2 п.п. к конверсии шоурум→сделка за счёт работы с возражениями и таргетного обучения (подробный расчёт — в гл. 12).

**\$98 / \$75**

CAPEX на менеджера (100 / 1000), бюджет \$100

**\$11.7 / \$8.9**

OPEX в мес (100 / 1000, консервативно), бюджет \$15

**$\approx$  1.8 с**

задержка подсказки на этапе 2 (цель  $\leq$  3 с)

**0 кнопок**

действий менеджера для записи смены

# Содержание

---

|                                                        |    |
|--------------------------------------------------------|----|
| Резюме решения .....                                   | 2  |
| 1. Постановка задачи, модель нагрузки, допущения ..... | 4  |
| 2. Ключевые архитектурные решения .....                | 6  |
| 3. Хардвер: бейдж, док-станция, площадочный шлюз ..... | 8  |
| 4. Аудиотракт и разделение голосов .....               | 12 |
| 5. Облачная архитектура и стек .....                   | 14 |
| 6. Пайплайн: путь данных от микрофона до CRM .....     | 16 |
| 7. CRM-модуль .....                                    | 18 |
| 8. Расчёты .....                                       | 20 |
| 9. Этап 2: подсказки в реальном времени .....          | 23 |
| 10. Надёжность, безопасность, право .....              | 26 |
| 11. Внедрение и человеческий фактор .....              | 28 |
| 12. Почему это будет полезно: модель ценности .....    | 30 |
| Приложение А. BOM бейджа: партномера .....             | 32 |
| Приложение Б. Цены и бенчмарки: источники .....        | 32 |
| Приложение В. Схема LLM-разбора .....                  | 33 |

# 1. Постановка задачи, модель нагрузки, допущения

## 1.1. Что строим

Сеть дилерских центров: 5 площадок, ~20 менеджеров на каждой. Менеджер проводит 5–8 живых разговоров с клиентами за смену, по 15–40 минут. Требуется: *этап 1* — захватывать разговоры в шоуруме, превращать в структурированный разбор и доводить до CRM и РОПа; *этап 2* — подсказки менеджеру в реальном времени. Ограничения: шумное открытое пространство, перемещения между машинами; Wi-Fi есть, но нестабильный и чужой; менеджеры — не технари и саботируют лишние действия; бюджет — до \$100 на железо на менеджера одновременно и до \$15/мес на облако и обработку; горизонт роста — 1000 менеджеров.

## 1.2. Модель нагрузки

| Параметр                         | Значение                                               | Комментарий                               |
|----------------------------------|--------------------------------------------------------|-------------------------------------------|
| Разговоров за смену на менеджера | 6.5 (5–8)                                              | середина диапазона из ТЗ                  |
| Средняя длительность разговора   | 27 мин (15–40)                                         | середина диапазона из ТЗ                  |
| Аудио разговоров за смену        | $6.5 \times 27 \approx 2.9$ ч                          | на менеджера                              |
| Смен в месяц                     | 22                                                     | график 5/2 либо 2/2 с ротацией — уточнить |
| Аудио в месяц на менеджера       | <b>64.3 ч</b>                                          | $2.92 \times 22$                          |
| Доля речи в аудио разговора      | 0.70                                                   | паузы, осмотр машины; после VAD           |
| Пиковый час (суббота)            | 60% менеджеров говорят одновременно                    | консервативно; см. гл. 8                  |
| Битрейт хранения                 | Opus 24 кбит/с, 16 кГц, моно-микс + метаданные каналов | 10.5 МБ/ч; достаточно для ASR (гл. 4)     |

Суммарно: 100 менеджеров генерируют **~292 ч аудио разговоров в сутки** (~205 ч чистой речи), 1000 менеджеров — ~2 925 ч. Это определяет размер вычислительного парка (гл. 8).

## 1.3. Явные допущения

- Смена  $\leq 11$  часов — от этого считается батарея бейджа (гл. 3).
- Один менеджер ведёт разговор с одним клиентом (парой клиентов); групповые экскурсии — вне скоупа качества диаризации, но записываются.
- CRM у заказчика самописная — значит, интеграционный контракт и модель данных задаём мы (гл. 7), а не подстраиваемся под чужой API.
- Юрисдикция — РФ: персональные данные обрабатываются только на территории РФ (гл. 10); цены на облако — российские провайдеры.

- Тест-драйвы (разговор в машине) — записываются тем же бейджем; это даже более ценные разговоры. Шумовой профиль другой (дорога), деградация WER допустима.

#### 1.4. Вопросы заказчику

Задание поощряет формулировать вопросы при нехватке данных. Ответы уточняют расчёты, но не меняют архитектуру — она устойчива к разбросу этих параметров:

1. График смен и часы работы площадок? (влияет на окно ночного LLM-батча и профиль пика)
2. Какая доля значимых разговоров происходит *вне* зоны Wi-Fi площадки — тест-драйвы, выездные показы? (влияет только на задержку доставки разбора, не на полноту)
3. Текучка менеджеров в год? (провижининг бейджей, объём ЗИП)
4. Есть ли на площадках проводной интернет, который можно арендовать под шлюз? (LTE тогда станет резервом — надёжнее и дешевле)
5. Требования СБ дилера: допустимо ли хранить аудио 6 месяцев, кто имеет право слушать записи, нужен ли on-premise вариант? (гл. 10)
6. Записываются ли сейчас телефонные звонки (колл-трекинг)? Если да — сопоставление визита с предшествующим звонком усилит связку с CRM (гл. 7)
7. Методология продаж (этапы воронки, скрипты, чек-листы), принятая в сети? Разбор LLM настраивается под неё (гл. 6); если формализованной нет — предложим стартовую.
8. Планируемая политика в отношении менеджеров: «записи для обучения» или «записи для контроля»? От этого зависит приживаемость (гл. 11) — рекомендуем первое.

## 2. Ключевые архитектурные решения

Шесть решений определяют всю систему. Каждое принято на пересечении ограничений задачи — шум, перемещения, чужой Wi-Fi, саботаж, \$100/\$15 — а не по отдельности.

| Решение                                                                                                                                                                                                  | Отвергнутые альтернативы и почему                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                               |
|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| <b>Д1. Захват звука: носимый бейдж собственной разработки</b><br>ESP32-S3, 2 MEMS-микрофона, microSD, Orpus на борту.<br>Микрофон в 20–25 см ото рта менеджера.                                          | <b>Потолочные/зонные микрофонные массивы</b> — разговор перемещается между машинами и уходит на улицу/в тест-драйв; в открытом зале массив ловит смесь соседних разговоров и вентиляции (расстояние до рта 2–4 м против 0.2 м у бейджа — это –20...–26 дБ прямого сигнала); стоимость покрытия зала выходит за бюджет; юридически это запись «всех подряд», а не участников сделки.<br><b>Смартфон менеджера</b> — в кармане даёт глухой звук; «достань и положи на стол» — действие, которое саботируют; BYOD неуправляем; корпоративный смартфон не влезает в \$100. <b>Готовые AI-рекордеры</b> (Plaud NotePin \$159, HiDock \$169–269) — дороже бюджета до всякой инфраструктуры, закрытая прошивка, привязка к чужому облаку (нарушение 152-ФЗ), нет док-станций и fleet-управления. Китайские OEM-бейджи (\$15–40 оптом) — рассматриваем как план Б для пилота (гл. 3.6). |
| <b>Д2. Сеть: своя инфраструктура на площадке</b><br>Собственная Wi-Fi AP + шлюз (мини-ПК) + LTE-аплинк. Wi-Fi дилера не используется вовсе.                                                              | <b>«Работать через Wi-Fi дилера»</b> — сеть чужая, нестабильная и не под нашим контролем: это прямое ограничение ТЗ, а не гипотеза. Любая архитектура, у которой от чужого Wi-Fi зависит сохранность данных, развалится в эксплуатации. У нас чужая сеть может быть лишь резервным аплинком шлюза. <b>«Бейджи с LTE-модемом каждый»</b> — +\$15–20 к BOM, +SIM на каждого, ×3 к энергопотреблению — незачем, когда данные не realtime-критичны (этап 1) и есть точка гарантированной выгрузки — док.                                                                                                                                                                                                                                                                                                                                                                            |
| <b>Д3. Разделение голосов: асимметрия каналов + лёгкая диаризация</b><br>«Кто говорит» решается физикой: голос менеджера всегда громче в его собственном бейдже. ruannote только подчищает дальнюю речь. | <b>Слепая диаризация одноканальной записи</b> — в шумном зале с соседними разговорами DER 20–25% даже у SOTA-моделей; ошибка в ролях обесценивает разбор («клиент возражал» ↔ «менеджер возражал»). <b>Идентификация по голосовым профилям (voice-ID)</b> — юридически переквалифицирует данные в биометрию (ст. 11 152-ФЗ): письменные согласия, УЗ-1/УЗ-2, штрафы за утечку 15–20 млн ₽. Запрещаем архитектурно (гл. 10).                                                                                                                                                                                                                                                                                                                                                                                                                                                     |
| <b>Д4. Обработка: батч в облаке РФ, self-hosted модели</b><br>ASR GigaAM-v3 + ruannote + LLM T-Pro 2.0 на арендных GPU класса RTX 4090; локально на устройстве — только VAD-гейтинг и Orpus.             | <b>Облачные ASR API</b> (SpeechKit, SaluteSpeech ≈ 36 ₽/ч) — 64 ч/мес × 36 ₽ ≈ 2 300 ₽ ≈ \$28/мес на менеджера: одна транскрибация съедает два бюджета. Отпадает арифметически (гл. 8). <b>Зарубежные API</b> — нарушение локализации 152-ФЗ. <b>Обработка на краю (шлюзе)</b> — N100 без GPU тянет VAD и упаковку, но не ASR 292 ч/сутки; GPU на каждой площадке дороже и сложнее в обслуживании, чем централизованный парк. <b>ASR на бейдже</b> — на ESP32 нереально (нужен ~GPU-класс).                                                                                                                                                                                                                                                                                                                                                                                     |

|                                                                                                                                                                                                                                 |                                                                                                                                                                                                                                                                                                             |
|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| <p><b>Д5. CRM: свой модуль в самописной CRM заказчика</b></p> <p>Проектируем модель данных, API-контракт и UI-модуль «Разговоры» как часть CRM (гл. 7).</p>                                                                     | <p><b>Интеграция «сбоку» через универсальные коннекторы</b> — не с чем интегрироваться: CRM самописная. Это преимущество: контракт задаём мы, сопоставление разговор→сделка получает нативную поддержку (календарь визитов, автосоздание лидов, подтверждение одним тапом), а не «запись в примечания».</p> |
| <p><b>Д6. UX менеджера: ноль действий</b></p> <p>Снял с дока — пишет; поставил — выгрузилось и заряжается. Один светодиод. Одна кнопка — «пауза 10 минут». Подтверждение сделок — 5–8 карточек в Telegram, 1 минута в день.</p> | <p><b>Любой UX со «включи запись»</b> — менеджеры «забудут» включать: это прямое ограничение ТЗ («саботируют всё, что усложняет им день»). Полнота записи должна достигаться по умолчанию, а не дисциплиной. Метрика приживаемости — % записанных смен — видна РОПу (гл. 11).</p>                           |




Рис. 1. Архитектура системы: площадка → облако РФ → CRM/РОП. Пунктир — контуры этапа 2.

Дальше документ раскрывает каждое решение: железо (гл. 3), аудиотракт (гл. 4), облако (гл. 5), пайплайн (гл. 6), CRM (гл. 7), расчёты (гл. 8), этап 2 (гл. 9), надёжность и юридику (гл. 10), внедрение (гл. 11), пользу (гл. 12).

### 3. Хардвер

Носимых устройств три класса: бейдж-рекордер (по числу менеджеров), док-станции и площадочный шлюз. Вся электроника — из серийных компонентов с открытых складов (LCSC/JLCPCB); цены проверены 17.08.2026 по живым тарифным сеткам и помечены в приложении Б источниками.

#### 3.1. Бейдж-рекордер: конструкция




Рис. 2. Блок-схема бейджа. Красные связи — силовые, чёрные — данные.

**Форм-фактор:** бейдж 95×65×12 мм на магнитной клипсе/шнурке, носится на груди вместо обычного именного бейджа (им же и является — печатная вставка с именем). Ориентация фиксирована клипсой: микрофон №1 смотрит вверх, в сторону рта носителя, №2 — фронтально, на собеседника. Вес ~90 г. Никаких экранов: RGB-светодиод и вибромотор не ставим — лишние цена/энергия (индикация — светодиод, статус — в Telegram-боте и на доке).

**Выбор SoC — ESP32-S3 (модуль ESP32-S3-WROOM-1-N16R8, \$3.62 @100).** Требования к чипу: два цифровых микрофона по I2S, кодирование Opus в реальном времени, файловая система на microSD, Wi-Fi для выгрузки, низкое потребление, зрелый SDK. ESP32-S3 закрывает всё: I2S-контроллер в std-режиме принимает два MEMS-микрофона как стерео (выбор канала пином WS); замер опубликованного порта Opus (fixed-point, Xtensa-DSP) даёт на 240 МГц **4.9× реального времени** при complexity 0 для 16 кГц моно — то есть кодек занимает ~20% одного ядра, второе остаётся ОС и файловой системе. Альтернатива nRF5340 (BLE-флагман Nordic, \$5.22) отвергнута: без Wi-Fi выгрузка ~50 МБ смены по BLE занимает часы — док-архитектура с ним не работает.

**Выбор микрофонов — 2× TDK ICS-43434 (\$2.78 @100 каждый).** Цифровой I2S-выход (24 бита) — аналоговый тракт и его наводки исключаются по построению. SNR 64 дБА — верх класса MEMS; AOP 120 дБ SPL — не клипует, даже если менеджер говорит громко в 20 см от капсуля. Рассматривались: INMP441 — фактически EOL (в серию закладывать нельзя), MSM261S4030H0 — дешевле, но SNR 57 дБА, экономия ~\$2 не стоит потери 7 дБ на шумном объекте. Акустика корпуса: капсули за мембранами Gore-типа (ветрозащита, IP54 передней панели), порты разнесены на 40 мм и развязаны резиновыми демпферами от корпуса (структурный шум одежды).



**Питание.** Энергобюджет режимов (по даташиту ESP32-S3 v2.2 и типовым значениям SD):

| Режим                                                          | Ток @3.7 В         | Доля смены |
|----------------------------------------------------------------|--------------------|------------|
| Запись: I2S + Orus (80–160 МГц) + буферизация RAM, Wi-Fi выкл. | 45–70 мА           | ~85%       |
| + сброс буфера на microSD (бёрсты раз в ~30 с)                 | +15–100 мА на <1 с | ~2%        |
| Wi-Fi выгрузка сегментов (TX до 283 мА пик)                    | ~120 мА средний    | ~3%        |
| Тишина: light-sleep с VAD-пробуждением                         | ~2–5 мА            | ~10%       |

Средневзвешенно  $\approx 55\text{--}75$  мА  $\rightarrow$  смена 11 ч  $\approx$  **600–830 мА·ч**. Аккумулятор LiPo 103450 **2000 мА·ч** (\$2.06) даёт запас  $>2\times$ : устройство доживает до конца смены и через два года деградации до 80% ёмкости, и при «забыл поставить в док» переживает вторую смену. Зарядка — BQ24074 (\$1.40): выбран из-за power-path (бейдж работает и выгружает данные, стоя в доке на зарядке — дешёвый TP4056 этого не умеет); MAX17048 (\$1.57) отдаёт честный процент батареи в телеметрию — «менеджер Иванов третий день не ставит бейдж в док» виден РОПу.

**Хранение.** microSD 32 ГБ (\$2.02). Смена в Orus 24 кбит/с  $\approx 50$  МБ — карта вмещает месяцы; фактическая политика — кольцевой буфер и удаление сегмента после подтверждённой загрузки в облако (по хэшу). eMMC отвергнут: дороже и превращает замену носителя в пайку. Сегменты по 5 минут: атомарная единица выгрузки/ретра; каждый шифруется AES-GCM ключом устройства (ключи — в eFuse, разговор невозможно прочитать с украденной карты) и подписывается (badge\_id, seq,  $t_0$ ,  $t_1$ , RMS-профили обоих каналов для канального приора диаризации).

**Прошивка (ESP-IDF/FreeRTOS), конечный автомат:** «в доке» (зарядка, полная выгрузка, OTA по подписанным образам, самотест микрофонов)  $\rightarrow$  «ношение: тишина» (light-sleep, энергетический VAD будит)  $\rightarrow$  «ношение: речь» (запись+Orus)  $\rightarrow$  «деградация» (SD-ошибка/батарея  $<10\%$  — красный светодиод, телеметрия). Часы синхронизируются NTP от шлюза при каждом контакте; дрейф RTC между синхронизациями  $<\pm 2$  с/сутки — достаточно для сопоставления с CRM. Единственная кнопка — «пауза 10 минут» (личный разговор): пауза логируется как событие, злоупотребление видно в статистике полноты записи.

### 3.2. BOM и себестоимость

| Позиция              | Компонент                               | @100 шт, \$ | @1000 шт, \$ |
|----------------------|-----------------------------------------|-------------|--------------|
| SoC-модуль           | ESP32-S3-WROOM-1-N16R8                  | 3.62        | 3.40         |
| Микрофоны $\times 2$ | TDK ICS-43434                           | 5.56        | 5.23         |
| Накопитель           | microSD 32 ГБ + держатель               | 2.32        | 2.05         |
| Аккумулятор          | LiPo 103450, 2000 мА·ч, PCM             | 2.06        | 1.96         |
| Зарядка/учёт         | BQ24074 + MAX17048 + LDO ME6211         | 3.00        | 2.51         |
| Разъёмы/индикация    | USB-C, WS2812B, кнопка, пого $\times 4$ | 0.55        | 0.45         |
| Пассив               | ~30 позиций, ESD, ферриты               | 1.50        | 1.20         |
| Плата и монтаж       | JLCPCB, 2 слоя, 50 $\times$ 90 мм       | 4.50        | 3.00         |

|                                        |                                                                 |            |            |
|----------------------------------------|-----------------------------------------------------------------|------------|------------|
| Корпус                                 | @100: MJF-печать · @1000: литьё (форма ~\$2 000 амортизирована) | 18.00      | 4.50       |
| Сборка                                 | финальная сборка, прошивка, тест, упаковка                      | 4.00       | 2.50       |
| <b>Итого BOM</b>                       |                                                                 | <b>≈45</b> | <b>≈27</b> |
| <b>+15% (брак, логистика, пошлины)</b> |                                                                 | <b>≈52</b> | <b>≈31</b> |

Ценовой риск при тираже 100 — корпус (MJF-печать даёт до трети себестоимости); резерв — вакуумное литьё в силикон (~\$8–10/шт на 100 шт) или запуск пресс-формы уже на пилотной партии, если решение о масштабировании принято. Реалистичность цен подтверждается рынком: китайские OEM-бейджи-рекордеры сопоставимой начинки продаются по \$15–40 оптом; Plaud NotePin (\$159) продаёт не железо, а подписку на софт.

### 3.3. Док-станция

Мульти-док на 10 мест (на площадку — два): наклонные слоты с пого-контактами (5 В, до 1 А на слот), БП 60 Вт, монтаж на стойке ресепшн/в комнате менеджеров. Вся логика в бейдже — док максимально глуп и дешёв (~\$120 за 10-местный в мелкой серии, референс — зарядные станции раций). Постановка в док — механический триггер конца смены: полная выгрузка остатков, зарядка, ОТА. Съём — старт записи и привязка «бейдж→менеджер» (менеджер берёт любой заряженный бейдж, тапнув по нему картой-пропуском/выбрав себя в Telegram-боте — двух вариантов достаточно, выбираем на пилоте; жёсткая персонализация бейджей проще, но умирает на подменах и забытых устройствах).

### 3.4. Площадочный шлюз



Рис. 3. Сеть площадки. Чужой Wi-Fi — только пунктирный резерв.

Шлюз — мини-ПК Intel N100/16 ГБ (26 900 Р): приём сегментов от бейджей через собственную точку доступа MikroTik hAP ax² (12 490 Р; отдельный SSID, WPA3, изолированный VLAN до шлюза), буфер на 7 дней (~1 ГБ/сутки с площадки), дедупликация, сборка смен, WireGuard/mTLS-туннель в облако, NTP для бейджей, кэш ОТА-образов, fleet-агент. Аплинк — LTE-роутер Keenetic Runner 4G (~9 000 Р) с SIM 35–150 ГБ (700–1500 Р/мес; трафик площадки ≈ 30 ГБ/мес); проводной интернет дилера, если дают

порт, — резерв (или наоборот: провод основной, LTE резерв — по площадке). На этапе 2 шлюз получает вторую роль: локальный детектор триггеров и быстрый путь подсказок (гл. 9) — N100 тянет это на CPU (T-one — 71.6М параметров, работает от 4 ядер).

### 3.5. CAPEX на менеджера

| Статья                              | @100, \$   | @1000, \$  |
|-------------------------------------|------------|------------|
| Бейдж (BOM + 15%)                   | 52         | 31         |
| ЗИП-фонд бейджей 10%                | 5          | 3          |
| Док-станция (доля слота)            | 12         | 12         |
| Шлюз+AP+LTE-роутер (÷20 менеджеров) | 29         | 29         |
| <b>Итого (бюджет \$100)</b>         | <b>≈98</b> | <b>≈75</b> |

При 100 менеджерах — на грани бюджета: резервы — корпус (–\$8), совмещение LTE-роутера со шлюзом (USB-модем, –\$5) и трактовка сетевой обвязки площадки как инфраструктурного, а не «поголовного» CAPEX. При 1000 — комфортный запас 25%.

### 3.6. План Б по железу (снятие риска разработки)

Собственный бейдж — 3–4 месяца до серийной партии (EVT→DVT→PVT). Чтобы не задерживать пилот и снять риск «железо не успело», параллельно закупается 10–20 китайских OEM бейджей-рекордеров (\$25–40) с записью на карту: они не умеют Wi-Fi-выгрузку и Orus, выгрузка через док-ридер на шлюзе, качество хуже — но пилотный поток данных и разработка облачной части стартуют в первый месяц. Прошивочный и облачный контракты совпадают, замена парка прозрачна.

### 3.7. Жизненный цикл парка (1000 устройств)

- **Провижининг:** на производстве в eFuse зашивается ключ устройства и серийник; активация — сканированием QR при поступлении на площадку; привязка к площадке автоматическая по первому контакту со шлюзом.
- **ОТА:** подписанные образы, staged-роллаут (1 площадка → 10% → все), откат по watchdog. Обновления — только в доке ночью.
- **Мониторинг флота:** батарея, ошибки SD, последняя выгрузка, % записанных смен — на дашборде; алерт РОПу и в саппорт при «бейдж молчит >24 ч».
- **RMA:** ЗИП 10% на площадке; замена = взять другой бейдж из дока (привязка не жёсткая); дефектные — почтой на базу, диагностический лог на SD.
- **Сертификация:** декларация соответствия ЕАЭС (ТР ТС 020/037), нотификация ФСБ на шифрование в составе устройства (типовая для Wi-Fi+AES изделий); закладываем 2 месяца и ~200 тыс. ₽ в NRE (не в поштучный CAPEX).

## 4. Аудиотракт и разделение голосов

### 4.1. Почему близкий микрофон побеждает шум физикой

Уровень прямого сигнала падает на 6 дБ с удвоением расстояния. Рот менеджера от его бейджа — 20–25 см; от потолочного массива — 2.5–4 м: разница **20–26 дБ** в пользу бейджа ещё до всякой обработки. Диффузный шум зала (вентиляция, соседние разговоры, шаги) при этом одинаков для обоих. На практике это переводит задачу из класса «далёкий микрофон в кафе» (WER 30–50%) в класс «гарнитура/телефония» (WER 9–17% у выбранной модели, см. 4.4). Второй микрофон бейджа, направленный фронтально, держит клиента на дистанции 0.5–1.5 м — хуже, чем канал менеджера, но радикально лучше любого стационарного варианта, и его сигнал усиливается тем, что клиент в диалоге почти всегда обращён к менеджеру.

### 4.2. Что считается на бейдже, что дальше

На устройстве — только дешёвое и необратимое: энергетический VAD-гейтинг (не пишем тишину), Opus 24 кбит/с (16 кГц моно-микс двух каналов + покadresовые RMS/спектральные метрики каждого канала в метаданных сегмента — 40 байт/с, они питают диаризацию), AES-GCM. Никакого шумоподавления на бейдже: необратимая обработка до ASR только вредит (модели обучены на сыром звуке), а вычислительно нейросетевой денойз ESP32 не тянет. Всё умное — в облаке, где его можно менять без перепрошивки парка.

### 4.3. Диаризация: двухступенчатая схема

**Ступень 1 — канальный приор (почти бесплатно, CPU).** Для каждого 20-мс кадра сравниваем энергию/спектральный наклон каналов «вверх» (рот носителя) и «фронт». Голос носителя даёт устойчивую разницу +12...+20 дБ в «своём» канале — сегменты «говорит менеджер» выделяются порогово с точностью, недостижимой для слепой диаризации, и *это не биометрия*: мы используем геометрию микрофонов, а не голосовой профиль личности (юридическая граница — гл. 10). Остаток — «дальняя речь»: клиент, второй клиент, соседний разговор, объявления по залу.

**Ступень 2 — кластеризация дальней речи (GPU, только по нужным кускам).** ruannote community-1 (CC-BY-4.0; DER на AMI 17.0%) в режиме exclusive-сегментации дочищает дальнюю речь: отделяет основного собеседника (стабильно громкий и чередующийся с менеджером) от фонового чужого разговора (не согласован по тайм-тейкингу, тише, прерывист). Эмбединги кластеризуются *внутри одного разговора* и уничтожаются после сегментации — межразговорная привязка «этот же клиент» по голосу не делается (снова граница биометрии). Выход: разметка РОЛЬ ∈ {менеджер, клиент(ы), фон} с таймкодами; фон в транскрипт не попадает.

**Перекрытия** (говорят одновременно — в живом споре до 15–20% времени): канальный приор работает и в перекрытии (у каждого источника свой доминантный канал), поэтому реплики менеджера восстанавливаются всегда; неразборчивые куски клиента помечаются low-confidence и не порождают «галлюцинированных» цитат в разборе (LLM получает confidence).

### 4.4. Выбор ASR: сравнение на русской спонтанной речи

| Модель | Лицензия | WER: телефония / callcenter / дальнее поле | Скорость (GPU) | Вердикт |
|--------|----------|--------------------------------------------|----------------|---------|
|--------|----------|--------------------------------------------|----------------|---------|

|                                    |            |                                   |                                                                                  |                                                                                      |
|------------------------------------|------------|-----------------------------------|----------------------------------------------------------------------------------|--------------------------------------------------------------------------------------|
| <b>GigaAM-v3 RNNT (Сбер, 220M)</b> | MIT        | 17.4 / 9.5 / 3.9 (Golos Farfield) | RTF 0.033 ( $\approx 30\times$ поток; $\sim 100\times$ + на 24 ГБ агрегированно) | <b>выбор для батча</b>                                                               |
| Whisper large-v3 (-turbo)          | MIT        | 27.4 / $\sim 19$ / 16.4           | 41 $\times$ (L4, batched) – 70–100 $\times$ (4090)                               | хуже в 1.5–2 $\times$ на нашем типе речи; резерв для мультязычности                  |
| T-one (Т-Банк, 71.6M)              | Apache 2.0 | 6.2–8.6 (телефония) / 8.63 / —    | стриминг, чанк 300 мс; CPU-ок                                                    | <b>выбор для этапа 2</b> (стриминг); в батче уступает GigaAM на неспонтанных доменах |
| Vosk 0.54                          | Apache 2.0 | avg 10.7 по 12 сетам              | стриминг CPU                                                                     | резерв для полностью офлайн-шлюза                                                    |
| NeMo Parakeet v3                   | NVIDIA OML | 16.0 avg (ru)                     | 239 $\times$ (L4)                                                                | быстрый, но качество на русском не конкурент                                         |

Числа — официальные evaluation-таблицы GigaAM/T-one и независимый бенчмарк alphacephei (12 русских датасетов); источники в приложении Б. Выбор GigaAM-v3 — это 1.5–2 кратное преимущество по WER на именно нашем классе звука (спонтанная речь, шум, дальнее поле для канала клиента) при MIT-лицензии и пригодной скорости. Модель 220M легко влезает в 4–6 ГБ VRAM — на одной RTX 4090 работают несколько воркеров параллельно.

#### 4.5. Сегментация смены на разговоры

Смена — непрерывный поток с дырами тишины. «Кандидат разговора» строится на шлюзе/в облаке: Silero VAD (MIT, CPU, <1 мс на кадр) собирает речевые интервалы; границы разговора — тишина >3 мин, исчезновение дальнего собеседника >5 мин при продолжающейся речи менеджера (закончил с клиентом, говорит с коллегами — фильтруется на ступени диаризации), постановка в док. Куски 15–40 мин с чередованием «менеджер ↔ дальний голос» — кандидаты; куски без чередования (совещание, обед) помечаются «не разговор с клиентом» и не анализируются LLM — экономия и приватность одновременно. Ошибка склейки двух клиентов в один разговор чинится на шаге сопоставления с CRM (гл. 7): менеджер видит карточку «2 клиента?» и делит одним тапом.

#### 4.6. Ожидаемое качество и деградационные режимы

- Канал менеджера: WER  $\sim 9$ –12% — достаточно для надёжного разбора аргументации менеджера.
- Канал клиента: WER  $\sim 15$ –25% в зале; смысловые единицы (возражения, имена, модели) LLM восстанавливает из контекста; confidence прокидывается до разбора и до UI (сомнительные цитаты подсвечены).
- Тест-драйв: дорожный шум — WER клиента до  $\sim 30\%$ ; факт и тематика разговора сохраняются.
- Мусорные сегменты (музыка, объявление, ветер) — отбрасываются VAD+диаризацией до ASR, GPU не тратится.
- Контроль качества постоянный: 1% разговоров в неделю — выборочная ручная оценка WER/DER разметчиком ( $\approx 3$  ч работы на 100 менеджеров), тренд — на дашборде качества (гл. 5).

## 5. Облачная архитектура и стек

### 5.1. Размещение

Всё, что касается персональных данных (аудио, транскрипты, разборы), живёт в российском облаке — это не предпочтение, а ч. 5 ст. 18 152-ФЗ (гл. 10). Основной контур — Selectel (выделенные GPU дешевле рынка, S3 2.29/1.14 ₽/ГБ, сегмент «облако 152-ФЗ» до УЗ-1) с почасовым бурстом GPU в immers.cloud; равноценные альтернативы — Яндекс Облако/VK Cloud (сводная таблица цен — приложение Б). Мультиклауд не городим: на нашем масштабе это усложнение без пользы, переезд страхуется тем, что весь стек — открытый софт в контейнерах поверх S3-совместимого API и PostgreSQL.

### 5.2. Стек и обоснование

| Слой                   | Выбор                                                       | Почему (и что отвергнуто)                                                                                                                                                                                                                   |
|------------------------|-------------------------------------------------------------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Сервисы API/ingest     | Go                                                          | дешёвые по CPU/RAM статически слинкованные сервисы, простая поставка; Python оставлен ML-воркерам, где экосистема решает                                                                                                                    |
| ML-воркеры             | Python (onnxruntime/CTranslate2, vLLM)                      | родная среда GigaAM/pyannote/T-Pro; изоляция в контейнерах по типам задач                                                                                                                                                                   |
| Очередь                | NATS JetStream                                              | лёгкая (один бинарь), персистентная, ack/retry/DLQ. Kafka отвергнута: managed-кластер от 13.4 тыс. ₽/мес и операционный вес ради потока в сотни сообщений/мин не оправданы; при 10× росте миграция тривиальна (интерфейс «очередь заданий») |
| БД                     | Managed PostgreSQL (+pgvector)                              | транскрипты JSONB, разборы, флот, идемпотентность; pgvector закрывает семантический поиск по разговорам без отдельного векторного хранилища. ClickHouse отложен до масштаба 1000+ (агрегаты пока тривиальны для PG)                         |
| Объектное хранилище    | S3-совместимое (Selectel/Яндекс)                            | аудио: standard 1 мес → cold, TTL 6 мес (лайфцикл-политики); 2.3/1.1 ₽/ГБ·мес                                                                                                                                                               |
| Оркестрация            | Docker Compose на BM (100 mpr) → Managed K8s (300+)         | на 100 менеджерах хватает 2 BM + GPU-нод; K8s-мастер и обвязка — когда парк GPU станет автоскейлиться (гл. 8)                                                                                                                               |
| ASR / диаризация / LLM | GigaAM-v3 · pyannote community-1 · T-Pro 2.0 32B AWQ (vLLM) | обоснование — гл. 4 и 6; все лицензии позволяют коммерческое использование (MIT / CC-BY-4.0 / Apache 2.0-производная)                                                                                                                       |
| Наблюдаемость          | VictoriaMetrics + Grafana + Loki, Sentry                    | лёгкий самостоятельный стек; три дашборда: флот, пайплайн, качество                                                                                                                                                                         |
| Доступ устройств       | WireGuard-туннели шлюзов, mTLS для бейджей                  | устройство = identity-сертификат; отзыв при краже                                                                                                                                                                                           |

### 5.3. GPU-парк: главный расчётный узел

Три задачи делят GPU класса RTX 4090 (24 ГБ): диаризация (дорогая:  $RTF_x \approx 15$  консервативно), ASR ( $RTF_x \approx 40$  консервативно с батчингом) и LLM-разбор (T-Pro 2.0 32B AWQ: ~180–300 разговоров в GPU-час). Днём приоритет у диаризации+ASR (свежие разговоры), LLM-очередь дожёвывается ночью — GPU загружены равномерно, покупать отдельный LLM-парк не нужно. Закупка гибридная: постоянная подписка (выделенный сервер 56 900 ₽/мес Selectel / 29 000 ₽ HOSTKEY) под ровное основание нагрузки + почасовая аренда (82.76 ₽/ч immers.cloud) под субботние пики и рост. Прерываемые инстансы (скидки до 75% у Selectel) — кандидат после пилота; батч-пайплайн переживает вытеснение по построению (задания идемпотентны, ретраи дешевы). Полные цифры по обоим масштабам — гл. 8.

### 5.4. Мониторинг как продукт, а не приложение

- **Флот:** % бейджей, вышедших на связь сегодня; % записанных смен (главная метрика приживаемости); батареи; очередь RMA. Алерты: «бейдж молчит 24 ч», «на площадке X доля записанных смен упала ниже 80%».
- **Пайплайн:** лаг очередей по стадиям (выгрузка→сегментация→ASR→LLM→CRM), SLA-таймер «разговор → карточка» (цель: 95% в тот же день), глубина ретраев, стоимость GPU-часа факт/план.
- **Качество:** WER-прокси (perplexity ASR, доля low-confidence), DER-выборки, доля разговоров без автосопоставления со сделкой (цель <15% после шага Б), доля отклонённых менеджерами сопоставлений.

## 6. Пайплайн: путь данных от микрофона до CRM

### Путь данных: от микрофона до карточки в CRM (этап 1)




Рис. 4. Восемь шагов пайплайна этапа 1 с задержками и точками сопоставления.

### 6.1. Контракты данных по шагам

| Шаг            | Артефакт                     | Формат/ключи                                                                                                                                   |
|----------------|------------------------------|------------------------------------------------------------------------------------------------------------------------------------------------|
| Бейдж → шлюз   | Сегмент 5 мин                | Opus + AES-GCM; заголовок: badge_id, seq, t <sub>0</sub> /t <sub>1</sub> , RMS-профили каналов, хэш                                            |
| Шлюз → облако  | Тот же сегмент               | батч-апплоад по WireGuard; ключ идемпотентности (badge_id, seq)                                                                                |
| Сборка         | Смена → кандидаты разговоров | shift_id; conversation_id = hash(badge, t <sub>0</sub> ); границы по VAD/диаризации/доку                                                       |
| Диаризация+ASR | Транскрипт                   | JSONL: {t <sub>0</sub> , t <sub>1</sub> , role: mgr client bg, text, conf}; хранится в PG (JSONB), аудио — в S3                                |
| LLM-разбор     | Analysis                     | строгий JSON по схеме (прил. В): этап сделки, возражения[{тип, отработано, цитата, t}], обязательства, чек-лист, оценки, сущности для матчинга |
| Сопоставление  | Связь conversation↔deal      | confidence + источник (А/Б/В); лог всех кандидатов                                                                                             |
| CRM            | Карточка разговора           | идемпотентный upsert по conversation_id; версия разбора                                                                                        |

### 6.2. Надёжность доставки



Правило одно: **каждый следующий хоп подтверждает приём, предыдущий только после этого удаляет**. Бейдж хранит сегмент до ask шлюза (место позволяет держать недели); шлюз — до ask облака (7 дней буфера); в облаке сегмент немедленно попадает в S3, и только потом в очередь обработки. Все стадии идемпотентны по естественным ключам — повторная доставка/обработка безвредна, exactly-once достигается на уровне эффекта (upsert), а не транспорта. Ретрай с экспонентой и DLQ; застрявшее в DLQ видно на дашборде пайплайна. Потерять разговор можно единственным способом — физически утопить бейдж до контакта со шлюзом.

### 6.3. LLM-разбор: чем «структурированный разбор» является технически

Один вызов T-Pro 2.0 (32B, vLLM, guided JSON по схеме) на разговор: вход — транскрипт с ролями и confidence + профиль сделки из CRM (этап, модель, история) + методология продаж сети (конфигурируемый чек-лист этапов: контакт → выявление потребности → презентация → тест-драйв → работа с возражениями → деньги/трейд-ин/кредит → следующий шаг). Выход-схема (прил. В) написана так, чтобы каждый факт имел таймкод-якорь в транскрипте — РОП по клику слушает первоисточник, галлюцинации проверяемы за секунды. Второй, дешёвый проход (~8B или правила) — PII-маскирование транскрипта для долгого хранения и обучающих подборок (гл. 10). Промпт и схема версионизируются; изменение — A/B на золотом наборе из 50 размеченных разговоров (создаётся на пилоте, гл. 11).

### 6.4. Сопоставление разговор ↔ сделка (вопрос 3 задания)

Три ступени, каждая закрывает свою долю случаев; цифры-цели по данным пилота:

1. **Контекст (авто, ~60–70%).** Мы знаем менеджера (бейдж), время (запись) и площадку. В CRM у менеджера есть календарь визитов/тест-драйвов. Пересечение по времени однозначно → связка готова. Здесь окупается «свой CRM-модуль»: визиты — первоклассная сущность (гл. 7), и чем дисциплинированнее ведутся, тем выше автосопоставление — метрика этого тоже видна РОПу.
2. **Содержание (авто, +15–20%).** LLM извлекает из транскрипта имя клиента, телефон (клиент диктует при записи на тест-драйв), модель, трейд-ин → fuzzy-поиск по клиентам/сделкам менеджера и площадки за  $\pm 30$  дней. Порог уверенности консервативный: ложная связка вреднее несвязанного разговора.
3. **Подтверждение (менеджер, 1 минута в день).** В конце смены Telegram-бот показывает 5–8 карточек: «15:20–15:55, обсуждали X5 в trade-in — это Иванов И.? [Да] [Выбрать] [Новый клиент]». «Да» — один тап; «Новый клиент» — автосоздание лида с предзаполнением из транскрипта (имя, телефон, интерес) — менеджеру это экономит ручной ввод, поэтому шаг воспринимается как польза, а не контроль. Неподтверждённое остаётся в очереди РОПа.

Все связки логируются с источником и уверенностью; ошибочную РОП/менеджер разрывают в один клик, разрыв — обучающий сигнал для порогов матчинга.


### 6.5. SLA этапа 1

Разговор, закончившийся до 16:00, — карточка в CRM в тот же день; вечерние — к 9:00 следующего дня. Основная задержка — не вычисления (пиковый час 100 менеджеров парк разбирает за  $\leq 2$  ч, гл. 8), а доставка хвостов записи при слабом аплинке; поэтому шлюз выгружает сегменты с приоритетом «сегодняшнее раньше вчерашнего», а бейджи начинают выгрузку оппортунистически в течение дня, не дожидаясь дока.

## 7. CRM-модуль

CRM у заказчика самописная — проектируем расширение как её родной модуль: три новые сущности вокруг существующих «клиент/сделка», один экран в карточке сделки, один дашборд, один бот. Ниже — контракт, который отдаётся команде CRM.

Модель данных CRM-модуля (ядро)



Аудио и транскрипты — в контуре аналитики (S3+PG, УЗ-3); CRM хранит ссылки и разбор. Retention: аудио 6 мес, транскрипты 24 мес (маскированные).

Рис. 5. Модель данных: синее — организация/парк, фиолетовое — существующее ядро CRM, зелёное — новые сущности аналитики.

### 7.1. Что появляется в CRM

- **Карточка разговора в сделке:** хронология всех разговоров по сделке; в каждом — итог одним абзацем, этап, чек-лист (что сделано/пропущено), возражения со статусом отработки, обязательства («обещал КП до пятницы» — автозадача менеджеру), плеер с прыжками по транскрипту от каждого факта разбора.
- **Дашборд РОПа:** воронка по этапам разговоров (где реально теряются сделки, а не где менеджер отметил); топ неотработанных возражений недели («дорого» — 34 случая, отработано 12); рейтинг менеджеров по чек-листу; динамика; сигналы «сделка под риском» (негатив клиента + нет следующего шага). Из любой цифры — проваливание до конкретных разговоров и аудио.
- **CoachingTask:** паттерн ошибок менеджера (три подряд неотработанных «дорого») автоматически превращается в задачу на обучение с примерами-разговорами; прогресс виден по следующим разговорам этого менеджера — обучение замыкается в цикл.
- **Telegram-бот менеджера:** подтверждение сопоставлений (гл. 6.4), выбор бейджа при заступлении, «мой разбор дня» — краткая сводка собственных разговоров (менеджер получает пользу лично, не только контроль — критично для приживаемости).

### 7.2. API-контракт (аналитика → CRM)

| Эндпоинт                      | Назначение                                                                              |
|-------------------------------|-----------------------------------------------------------------------------------------|
| PUT<br>/v1/conversations/{id} | идемпотентный upsert карточки разговора (статус: recorded→transcribed→analyzed→matched) |

|                                     |                                                             |
|-------------------------------------|-------------------------------------------------------------|
| PUT /v1/conversations/{id}/analysis | разбор (версионизируемый JSON, прил. В)                     |
| POST /v1/conversations/{id}/match   | предложение связки со сделкой {deal_id, confidence, source} |
| POST /v1/leads                      | автосоздание лида из неопознанного разговора                |
| GET /v1/managers/{id}/visits?date=  | календарь визитов для ступени А матчинга                    |
| GET /v1/deals/search?q=             | fuzzy-поиск сделок для ступени Б                            |
| POST /v1/coaching-tasks             | задача обучения из паттерна ошибок                          |
| WS /v1/alerts                       | сигналы «сделка под риском», алерты флота для РОПа          |

Аудио и сырые транскрипты в CRM не копируются: CRM хранит разбор и ссылки, плеер стримит из контура аналитики с проверкой прав (RBAC: менеджер слышит своё, РОП — свою площадку, HR/обучение — только обезличенные подборки). Это держит периметр персональных данных компактным (гл. 10) и не раздувает базу CRM.

### 7.3. Почему связка получается надёжной именно в своей CRM

Ключевая проблема «кусоч непрерывной записи ↔ сделка» — не алгоритмическая, а процессная: в чужой CRM визиты ведутся как попало, и матчить не с чем. В своей CRM мы делаем визит первоклассной сущностью с дешёвым вводом (запись на тест-драйв и так фиксируется), а недостающее закрываем однопоточным подтверждением менеджера, которое одновременно экономит ему ручное заполнение CRM (автолиды, автозадачи из обязательств). Так у всех трёх участников — алгоритма, менеджера, РОПа — совпадают стимулы, и доля сопоставленных разговоров растёт со временем (метрика на дашборде качества).

## 8. Расчёты

Все формулы приведены явно; цены — август 2026, источники в приложении Б; курс 83 ₽/\$. Расчёты продублированы скриптом (репозиторий проекта), сценарии: *консервативный* (нижние оценки скорости моделей, дорогой GPU-провайдер) и *оптимистичный* (верхние реалистичные оценки, дешёвый провайдер). Бюджету должен удовлетворять консервативный.

### 8.1. Поток аудио в пиковый час

Пик — суббота, день: одновременно говорят 60% менеджеров.

|                                  | 100 менеджеров                                                          | 1000 менеджеров    |
|----------------------------------|-------------------------------------------------------------------------|--------------------|
| Одновременных разговоров         | $100 \times 0.6 = 60$                                                   | <b>600</b>         |
| Суммарный поток (Opus 24 кбит/с) | $60 \times 24 = 1.4$ Мбит/с                                             | <b>14.4 Мбит/с</b> |
| На одну площадку (12 разговоров) | 0.3 Мбит/с — на порядки ниже ёмкости LTE; сеть не является узким местом |                    |
| Аудио, порождённое пиковым часом | 60 ч (42 ч речи)                                                        | 600 ч (420 ч речи) |

### 8.2. Параллельные обработчики

Скорости обработки на GPU класса RTX 4090 (обоснование — гл. 4; RTFx = часов аудио на GPU-час): ASR GigaAM-v3 — 40 (конс.) / 100 (опт.); диаризация ruannote с канальным приором — 15 / 50; LLM-разбор T-Pro 2.0 32B — 180 / 300 разговоров в GPU-час.

Суточная потребность, GPU-часов (100 менеджеров, консервативно): ASR:  $205 \text{ ч речи} \div 40 = 5.1$ ; диаризация:  $205 \div 15 = 13.7$ ; LLM:  $650 \text{ разговоров} \div 180 = 3.6$ ; итого **22.4 GPU-ч/сутки** — покрывается почасовой арендой одной 4090 (соответствие «число параллельных обработчиков»: днём 2 GPU-эквивалента, ночью 1). Пиковый час порождает 3.85 GPU-ч работы → при двух активных GPU разбирается за ~2 часа — внутри SLA (гл. 6.5). На 1000 менеджеров: 224 GPU-ч/сутки — **парк 10–12 × 4090** (консервативно) или 4–5 (оптимистично), с автоскейлом почасовых под субботы.

### 8.3. Хранение

На менеджера:  $64.3 \text{ ч/мес} \times 10.5 \text{ МБ/ч} \approx 0.66 \text{ ГБ/мес}$  нового аудио. Ретенция 6 мес (юридическая рекомендация, гл. 10): steady-state 4 ГБ/менеджера. Первый месяц — standard (2.3 ₽/ГБ), остальное — cold (1.1 ₽/ГБ):

|                      | 100 менеджеров | 1000 менеджеров |
|----------------------|----------------|-----------------|
| Новое аудио в месяц  | 66 ГБ          | 663 ГБ          |
| Steady-state (6 мес) | 398 ГБ         | 3 977 ГБ        |
| Стоимость в месяц    | ~520 ₽         | ~5 170 ₽        |

Хранение — статистическая погрешность бюджета (<1%): экономить на ретенции незачем, ограничивает её юридика, а не деньги. Транскрипты и разборы (~1 МБ на менеджера в месяц в PG)

— пренебрежимо.

## 8.4. Месячный OPEX

| Статья, Р/мес                                                                    | 100 менеджеров |               | 1000 менеджеров |                |
|----------------------------------------------------------------------------------|----------------|---------------|-----------------|----------------|
|                                                                                  | конс.          | опт.          | конс.           | опт.           |
| GPU (аренда: часы × 82.76 Р либо выделенные 29–57 т.Р/мес — оптимум по масштабу) | 56 300         | 20 900        | 563 100         | 131 800        |
| Хранение S3                                                                      | 520            | 520           | 5 170           | 5 170          |
| Бэкенд-фикс: BM ×2–3, Managed PG, мониторинг                                     | 35 000         | 35 000        | 120 000         | 120 000        |
| LTE площадок (×5 / ×50)                                                          | 5 000          | 5 000         | 50 000          | 50 000         |
| <b>Итого, Р</b>                                                                  | <b>96 800</b>  | <b>61 400</b> | <b>738 300</b>  | <b>307 000</b> |
| <b>На менеджера, \$/мес (бюджет \$15)</b>                                        | <b>11.7</b>    | <b>7.4</b>    | <b>8.9</b>      | <b>3.7</b>     |

Комментарии. (1) Крупнейшая статья на малом масштабе — фиксированный бэкенд: юнит-экономика улучшается с ростом сама. (2) LLM-разбор в таблице «бесплатен»: он выполняется в купленные GPU-часы (3.6 ч/сутки из 22.4); альтернатива — GigaChat Pro batch API (3.38 Р/разговор = 48 300 Р/мес на 100 менеджеров = +\$5.8/менеджера) — законная запаска, если свой LLM-контур захочется отложить, бюджет всё ещё сходится (\$17.5 — на грани, поэтому запаска, а не план). (3) Почему не API-распознавание: SpeechKit/SaluteSpeech ≈ 36 Р/час аудио × 64.3 ч = **2 315 Р = \$28/мес на менеджера за один только ASR** — вдвое выше всего бюджета; это решение продиктовано арифметикой, а не вкусом.

## 8.5. Чувствительность

| Фактор                                     | Диапазон     | Эффект на \$/менеджера (100 mgr)           |
|--------------------------------------------|--------------|--------------------------------------------|
| RTFx диаризации (главная неопределённость) | 15 → 50      | –2.9                                       |
| Цена GPU-часа (immers → HOSTKEY-класс)     | 82.76 → 40 Р | –3.4                                       |
| Разговоров/смена                           | 6.5 → 8      | +1.6                                       |
| Курс Р/\$                                  | 83 → 100     | –2.0 (расходы рублёвые, бюджет долларовый) |
| Доля речи после VAD                        | 0.70 → 0.85  | +1.2                                       |

Худший разумный стек факторов (8 разговоров/смена + 85% речи одновременно: ~\$14.8) подходит к бюджету впритык — и лечится любым из трёх рычагов: тюнинг диаризации (батчинг эмбедингов — известные 3–5× у ruannote), скидки предоплаты GPU (10–50% у immers), выделенные серверы при стабильной загрузке. Запас прочности бюджета оцениваем как достаточный.

## 8.6. CAPEX (сводно; вывод BOM — гл. 3)

100 менеджеров: бейдж \$52 + ЗИП 10% + док \$12 + сеть площадки \$29 = **\$98** (бюджет \$100). 1000: **\$75**. Парк целиком: \$9 845 и \$75 350 соответственно — примечательно, что весь CAPEX программы на 100 менеджеров меньше месячного фонда оплаты труда двух менеджеров.


## 9. Этап 2: подсказки в реальном времени

### 9.1. Что меняется в системе

Этап 1 спроектирован так, чтобы этап 2 был включением, а не перестройкой: бейдж уже кодирует Orus кадрами по 20 мс — добавляется их стриминг по Wi-Fi на шлюз (параллельно записи на SD; энергетика — гл. 9.5); шлюз уже стоит на площадке — на нём поднимается быстрый контур; в облаке добавляется пул стриминговых ASR-воркеров. Запись и батч-разбор этапа 1 продолжают работать без изменений — стриминг лишь дополнительный потребитель тех же кадров.

### 9.2. Бюджет задержки

Этап 2: бюджет задержки подсказки (от слов клиента до вибрации на часах)



Пауза в реплике клиента (600 мс тишины) финализирует фразу — подсказка приходит в естественной паузе, а не перебивает.

**Быстрый путь (без LLM): триггер по ключевым фразам на шлюзе  $\rightarrow$  готовый шаблон  $\approx 0.7$  с.**

Деградация: нет интернета  $\rightarrow$  работает только быстрый путь; нет Wi-Fi до шлюза  $\rightarrow$  подсказок нет, запись продолжается.

Рис. 6. Водопад задержки LLM-подсказки; быстрый путь на шлюзе — 0.7 с.

| Звено                                       | Задержка                          | Обоснование                                                                             |
|---------------------------------------------|-----------------------------------|-----------------------------------------------------------------------------------------|
| Захват + кадрирование Orus + Wi-Fi до шлюза | $\sim 120$ мс                     | кадр 20 мс, джиттер-буфер 60–80 мс на потери Wi-Fi                                      |
| Шлюз $\rightarrow$ облако                   | $\sim 80$ мс                      | LTE RTT 40–70 мс типично для РФ-сетей                                                   |
| Стриминговый ASR (T-one)                    | $\sim 330$ мс partial             | документированная эмиссия: чанк 300 мс; финализация фразы 1–1.2 с (порог тишины 600 мс) |
| Детектор триггера                           | $\sim 50$ мс                      | правила + лёгкий классификатор по скользящему окну транскрипта                          |
| Генерация подсказки LLM 8B                  | $\sim 800$ мс                     | подсказка $\leq 30$ токенов; TTFT+декод на выделенном инференсе (QVikhr-3-8B класс)     |
| Доставка на телефон/часы                    | $\sim 400$ мс                     | WebSocket на телефон по Wi-Fi/LTE + зеркалирование уведомления на часы                  |
| Итого LLM-путь                              | $\approx 1.8$ с (разброс 1.5–3 с) | цель $\leq 3$ с: подсказка успевает в естественную паузу диалога                        |

|                                        |               |                                                                                                     |
|----------------------------------------|---------------|-----------------------------------------------------------------------------------------------------|
| <b>Быстрый путь (шлюз, без облака)</b> | <b>≈0.7 с</b> | T-one на CPU шлюза + библиотека готовых шаблонов («упомянут трейд-ин → напомнить про акцию оценки») |
|----------------------------------------|---------------|-----------------------------------------------------------------------------------------------------|

Почему это честные цифры: единственное неочевидное звено — стриминговый ASR — взято из открытого бенчмарка T-one (Apache 2.0, обучен на 80 тыс. ч русской телефонии, WER 8.6% на колл-центре — лучший класс для нашего звука). Ключевое продуктивное решение, экономящее секунды: подсказка не «суфлёр в ухо посреди фразы», а короткий nudge в паузе — финализация фразы клиента (600 мс тишины) сама попадает в момент, когда менеджер может взглянуть на часы.

### 9.3. Куда доставлять подсказку

| Канал                                       | Плюсы/минусы                                                                                                  | Вердикт                                      |
|---------------------------------------------|---------------------------------------------------------------------------------------------------------------|----------------------------------------------|
| <b>Часы (Redmi Watch 5 Active, 2 699 ₽)</b> | вибро + 5–7 слов; взгляд на часы социально нейтрален; свой SDK не нужен — зеркалирование уведомлений телефона | <b>основной</b>                              |
| Телефон менеджера (приложение)              | полный текст, история подсказок; телефон в руках при клиенте — плохо                                          | носитель канала для часов + разбор после     |
| Наушник (~600 ₽)                            | голосовая подсказка незаметна... и слышна клиенту ощущением «менеджеру суфлируют»; выглядит как неуважение    | отвергнут для шоурума; опция для колл-центра |

### 9.4. Что подсказываем (и чего не обещаем)

Реалистичные и полезные классы подсказок: чек-лист этапа («не спросил про трейд-ин»), реакция на триггер-фразы («дорого» → напомнить про рассрочку/остаточный платёж; «подумаю» → предложить закрепить тест-драйв), комплаенс («озвучь обязательное уведомление о записи»), сигнал РОПу «подойди, сделка греется/горит» (менеджер не справляется — старший включается вживую: организационная подсказка часто ценнее текстовой). Не обещаем: полного суфлёра, генерации аргументации на лету в ухо, анализа эмоций как продукта (сырой сигнал тона — максимум как второстепенная фишка РОПу). Причина — не техника, а UX: менеджер, читающий простыню с часов, продаёт хуже, чем менеджер без подсказок.

### 9.5. Нагрузка и стоимость этапа 2

- **Бейдж:** стриминг добавляет Wi-Fi TX почти постоянно → среднее потребление растёт с ~60 до ~110–130 мА; батарея 2000 мА·ч держит смену на пределе (11 ч × 120 мА = 1320 мА·ч < 1600 доступных с деградацией). Решения: стримить только при детекции дальней речи (разговор, а не хождение), в остальное время — heartbeat; при батарее <30% — стриминг off, запись остаётся. Запас в BOM на ревизию В: посадочное место под 2500 мА·ч.
- **Стриминговый ASR-пул:** пиковый час 1000 менеджеров = 600 одновременных потоков; T-one на TensorRT держит тысячи потоков на одной A100 (бенчмарк: 7 833 потока) — хватает 1 A100 (212–316 ₽/ч только в рабочие часы ≈ 25–40 тыс. ₽/мес на всю сеть из 1000) либо 2–3 × 4090. На 100 менеджеров — стриминг-контур живёт на тех же 4090, что и батч.
- **LLM-подсказки:** 8B-модель, ~1 вызов на 2–3 минуты активного разговора, ≤30 токенов ответа → одна 4090 обслуживает ~200+ одновременных разговоров; +1 GPU на 100 менеджеров с запасом.



- **Итого +\$2–3/менеджера/мес** к OPEX этапа 1 (GPU стриминга + LLM + часы ~2 700 ₽ единовременно на менеджера, если часов ещё нет). Бюджет \$15 выдерживает оба этапа в консервативном сценарии ( $\$11.7 + \$2.5 \approx \$14.2$ ); часы в CAPEX выходят за \$100 на ~\$33 @100 — фиксируем как осознанное превышение этапа 2 (альтернатива — телефон без часов, \$0).

## 9.6. Деградация этапа 2

Нет облака (LTE лёг) → быстрый путь на шлюзе продолжает давать шаблонные подсказки (0.7 с). Нет Wi-Fi до шлюза (менеджер на тест-драйве) → подсказок нет, запись продолжается, батч-разбор не страдает. Этап 2 — надстройка, отказ которой никогда не трогает этап 1.

## 10. Надёжность, безопасность, право

### 10.1. Отказы: что ломается и что происходит

| Отказ                                | Поведение системы                                                                                   | Что теряем                                                                                  |
|--------------------------------------|-----------------------------------------------------------------------------------------------------|---------------------------------------------------------------------------------------------|
| Wi-Fi площадки лёг                   | бейджи копят на SD (недели ёмкости);<br>выгрузка при восстановлении или в доке                      | ничего; задержка разбора                                                                    |
| LTE и провод легли<br>одновременно   | шлюз копит 7 дней; бейджи выгружаются в<br>него штатно                                              | ничего; задержка                                                                            |
| Шлюз умер                            | бейджи копят на SD; замена шлюза —<br>типовой мини-ПК, конфиг из облака, 1 час                      | ничего; задержка + этап 2 на площадке<br>offline                                            |
| Бейдж утоплен/<br>разбит до выгрузки | —                                                                                                   | невыгруженные разговоры (обычно $\leq 1$<br>смены) — единственный сценарий<br>потери данных |
| Облако недоступно                    | шлюзы копят; пайплайн догоняет после<br>восстановления (парк GPU переразмерен к<br>среднему в 2–3×) | ничего; SLA-задержка                                                                        |
| GPU-провайдер<br>деградировал        | переезд воркеров на почасовые у второго<br>провайдера (образы провайдеро-<br>независимы)            | часы задержки разбора                                                                       |
| Менеджер<br>«забывает» бейдж         | телеметрия: % записанных смен падает →<br>виден РОПу                                                | данные этого менеджера; лечится<br>процессом (гл. 11), а не техникой                        |

### 10.2. Безопасность

- **Устройство:** ключ в eFuse, сегменты AES-GCM — украденный бейдж/карта не читаются; mTLS-идентичность на устройство, отзыв сертификата при пропаже; подписанные OTA.
- **Транспорт:** WPA3 на своей AP, WireGuard шлюз→облако; бейджи не видят интернет вообще (VLAN только до шлюза).
- **Облако:** шифрование S3 at-rest, доступ к аудио — только через сервис выдачи с RBAC и журналированием каждого прослушивания (кто, что, когда — журнал виден СБ); прод-доступ инженеров — по break-glass процедуре.
- **Минимизация:** PII-маскирование транскриптов вторым проходом (имена, телефоны, паспорта); обучающие подборки — только маскированные; фрагменты со спецкатегориями (здоровье, семья — клиент случайно рассказал) детектируются LLM и вырезаются из хранения (юридическое требование, см. ниже).

### 10.3. Правовая конструкция (РФ, август 2026)

Проверено по первоисточникам и разъяснениям (список — прил. Б); финальный пакет документов подлежит валидации практикующим юристом по ПДн.

- **Запись — персональные данные, но не биометрия**, пока голос не используется для установления личности (ст. 11 152-ФЗ: оба условия должны выполняться). Поэтому в системе —

**архитектурный запрет voice-ID:** роли определяются геометрией микрофонов (гл. 4), голосовые профили не строятся и не хранятся. Нарушение этой границы переводит систему в режим биометрии: письменные согласия, УЗ-1/УЗ-2, штраф за утечку 15–20 млн ₽.

- **Основание обработки клиентов** — связка: заметные таблички «ведётся аудио- и видеозапись» + устное уведомление в начале предметного разговора (пункт скрипта менеджера, контролируется самим же разбором) + **явное согласие отдельным документом** на этапе анкеты/записи на тест-драйв (с 01.09.2025 согласие — только обособленная форма) + п. 5 ч. 1 ст. 6 152-ФЗ (преддоговорные отношения) для реальных покупателей. «Зашёл поглазеть» без последующего контакта — разговор не персонализируется: остаётся анонимной статистикой без связки с CRM, аудио удаляется по короткому TTL (30 дней).
- **Сотрудники:** ЛНА «о контроле качества обслуживания» (цели: контроль качества, обучение, разбор споров; доступы; сроки), ознакомление под подпись, доп. соглашения; использование записей только в заявленных целях — дисциплинарка на записях при цели «обучение» юридически уязвима, это же условие приживаемости (гл. 11). Арбитражная практика запись переговоров сотрудников с клиентами при ЛНА поддерживает.
- **Локализация (ч. 5 ст. 18):** весь конвейер в РФ; зарубежные ASR/LLM API исключены архитектурно (штраф 1–6 млн ₽, повторно 6–18 млн). Облако — сегмент «152-ФЗ» (УЗ-3 целевой уровень по ПП 1119), договор поручения обработки с провайдером.
- **Оператор:** уведомление РКН (обновить: цели, аудио, облако), политика, ответственный, модель угроз, меры приказа ФСТЭК №21, регламент утечек 24 ч/72 ч. Лицензии ФСТЭК не требуется (обрабатываем собственные ПДн).
- **Ретенция:** аудио 6 мес (авто-TTL в S3), маскированные транскрипты 24 мес, разборы/агрегаты — без ПДн, бессрочно. Права субъектов: выдача/удаление по запросу — реализуется штатным API (данные и так связаны с клиентом в CRM).
- **Главный риск — утечка массива записей:** > 1 000 субъектов → 3–5 млн ₽, повторно — оборотный штраф 1–3% выручки (от 20 млн). Дизайн минимизации: компактный периметр аудио (один сервис выдачи), маскирование, вырезание спецкатегорий, короткая ретенция, журналирование доступа. Тайна связи (126-ФЗ) к живым разговорам не применяется — подтверждено; при добавлении записи телефонии потребуется отдельный контур.

## 11. Внедрение и человеческий фактор

### 11.1. Анти-саботаж как проектное требование

«Менеджеры не технари и саботируют всё, что усложняет им день» — главное небюджетное ограничение ТЗ. Ответ на него распределён по всей системе, здесь сведён воедино:

- **Ноль действий для записи:** снял бейдж с дока — работает; поставил — выгрузился и заряжается. Бейдж заменяет обычный именной — не «дополнительный предмет».
- **Личная польза раньше контроля:** автолиды и автозадачи из разговора экономят менеджеру ввод в CRM; «мой разбор дня» в Telegram помогает не забыть обещанное клиенту; подтверждение сопоставлений — 1 минута.
- **Политика «запись для обучения, не для наказаний»**, закреплённая в ЛНА и публично объявленная: без неё бейджи начнут «тонуть в кофе». Дисциплинарные решения на записях, кроме грубых нарушений (хамство, обман клиента), — запрещены политикой; это совпадает с юридической рекомендацией (гл. 10).
- **Кнопка «пауза 10 минут»** — легальный клапан приватности; злоупотребление видно в статистике полноты, вопрос решает РОП процессно.
- **Прозрачная метрика приживаемости:** % записанных смен по менеджеру и площадке — на дашборде РОПа; цель  $\geq 85\%$  к концу пилота.

### 11.2. Пилот (одна площадка, 8 недель)

| Недели | Работы                                                                                                                  | Выходной критерий                                                                                                             |
|--------|-------------------------------------------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------------------------------------------------|
| 1–2    | монтаж шлюза/AP/доков; 5 менеджеров-волонтеров с OEM-бейджами (план Б, гл. 3.6); юрпакет: таблички, ЛНА, формы согласий | записи идут, выгрузка стабильна                                                                                               |
| 3–4    | включение пайплайна; сбор золотого набора (50 разговоров с ручной разметкой); калибровка сегментации и матчинга         | WER на канале менеджера $\leq 12\%$ ; $\geq 60\%$ авто-сопоставлений                                                          |
| 5–6    | карточки в CRM и дашборд РОПу; Telegram-бот менеджерам; расширение до 20 менеджеров, замена на свои бейджи (EVT-партия) | $\geq 80\%$ записанных смен; РОП пользуется дашбордом еженедельно (факт логина и разборов)                                    |
| 7–8    | прогон недельного цикла обучения: паттерн ошибок → CoachingTask → контроль динамики; замер юнит-экономики факта         | $\geq 75\%$ авто-сопоставлений после шага Б; OPEX-факт $\leq \$15$ ; менеджеры-волонтеры рекомендуют систему коллегам (опрос) |

Стоп-критерии пилота (честные): полнота записи  $< 60\%$  при исправном железе (саботаж не лечится UX'ом — вопрос к политике мотивации), WER канала менеджера  $> 20\%$  (акустическая гипотеза не подтвердилась — пересмотр микрофонной схемы), авто-сопоставление  $< 40\%$  (дисциплина визитов в CRM нулевая — сначала процессный проект в CRM, потом аналитика).

### 11.3. Роллаут на 5 площадок и рост до 1000

Волнами по 1–2 площадки в 2 недели: монтаж — 1 день (шлюз+АР+доки), обучение РОПа — 2 часа, менеджерам — 15-минутный стендап («бейдж вместо вашего обычного, вот док, вот бот»). Рост до 1000 менеджеров не меняет архитектуру (гл. 8): парк GPU 10–12 карт, РСВА-партия 1000 бейджей (себестоимость падает до \$31), команда сопровождения — 1 инженер флота на ~300 устройств + саппорт-линия в Telegram. Узкое место масштабирования — не техника, а онбординг РОПов: дашборд без привычки им пользоваться — мебель; поэтому в роллаут-план заложен еженедельный 30-минутный разбор с каждым РОПом первые 4 недели площадки.

## 12. Почему это будет полезно: модель ценности

### 12.1. Что руководство получает впервые

Сегодня о содержании 650 разговоров в день на сеть известно ровно то, что менеджеры записали в CRM — то есть почти ничего, и с систематическим искажением («клиент думает» вместо «я не отработал возражение»). Система делает разговор наблюдаемой единицей управления:

- **Воронка по фактическим этапам разговора**, а не по отметкам менеджера: где реально теряются сделки (не дошли до тест-драйва? споткнулись о трейд-ин? отпустили «подумать» без следующего шага?).
- **Карта возражений**: топ-возражения недели × доля отработанных × у кого получается (их формулировки — в обучение остальным: библиотека лучших ответов собирается из собственных звёзд, а не из книжек).
- **Таргетное обучение**: CoachingTask по паттерну ошибок конкретного менеджера с примерами из его же разговоров; прогресс измерим по следующим разговорам. Онбординг новичка: библиотека эталонных разговоров + разбор его первых диалогов — выход на план быстрее.
- **Ранние сигналы по сделкам**: «горячий клиент без следующего шага», «обещание не выполнено», «конкурент упомянут трижды» — РОП вмешивается, пока сделка жива.
- **Голос клиента для маркетинга**: что спрашивают, что сравнивают, какие акции упоминают — агрегированно и без ПДн.

### 12.2. Расчёт окупаемости (консервативный)

Площадка 20 менеджеров: ~2 860 разговоров-визитов в месяц; при конверсии шоурум→сделка 15% это ~430 продаж... — для консервативности возьмём официальную статистику хуже: пусть уникальных клиентов-визитов 1 200/мес (часть разговоров — повторные), конверсия 15% = 180 продаж/мес, маржа 80 тыс. ₽ с автомобиля (нижний край для дилера с учётом допов/кредита/трейдинга).

|                                                             | Значение                                                                                                  |
|-------------------------------------------------------------|-----------------------------------------------------------------------------------------------------------|
| Стоимость системы на площадку (этап 1, конс.)               | $20 \times \$11.7 \times 83 \approx$ <b>19 400 ₽/мес</b>                                                  |
| Безубыточность                                              | $19\,400 \div 80\,000 =$ <b>0.25 автомобиля в месяц</b> , т.е. +0.02 п.п. к конверсии (0.25/1200 визитов) |
| Реалистичный эффект: +1 п.п. конверсии (12 доп. продаж/мес) | +960 тыс. ₽ маржи/мес на площадку → <b>ROI <math>\approx</math> 50×</b>                                   |
| Только «спасённые» сделки по ранним сигналам (2/мес)        | +160 тыс. ₽/мес → ROI $\approx$ 8× даже без роста конверсии                                               |

Отраслевые данные по речевой аналитике телефонии дают +5–15% к конверсии обработанных контактов; мы сознательно считаем окупаемость от +0.02 п.п. — порога, который проходится при любом различимом эффекте вообще. Асимметрия риска: даунсайд — \$98 CAPEX и \$11.7/мес на менеджера; апсайд — единицы процентов конверсии на марже автомобилей.

### 12.3. Проверяемость эффекта

Эффект меряется по дизайну, а не по ощущениям: роллаут волнами даёт естественный A/B (площадки с системой vs без), метрики фиксируются до старта (конверсия, средний чек допов, скорость прохождения этапов, выполнение обещаний клиентам). Отчёт «эффект за квартал» — часть продукта (дашборд руководства сети), потому что покупает систему не РОП, а владелец сети — и ему нужен ответ «сколько это принесло», а не «сколько разговоров записано».

## Приложение А. ВОМ бейджа: партномера

| Компонент            | Партномер                                    | Примечание                                            |
|----------------------|----------------------------------------------|-------------------------------------------------------|
| SoC-модуль           | ESP32-S3-WROOM-1-N16R8                       | 16 МБ flash / 8 МБ PSRAM; LCSC C2913202               |
| Микрофоны ×2         | TDK InvenSense ICS-43434                     | I2S 24 бит, SNR 64 дБА, AOP 120 дБ SPL; LCSC C5656610 |
| Зарядка + power-path | TI BQ24074RGTR                               | работа при зарядке в доке; LCSC C54313                |
| Fuel gauge           | Maxim MAX17048G+T10                          | % батареи в телеметрию; LCSC C2682616                 |
| LDO 3.3 В            | ME6211C33 (500 мА, IQ 60 мкА)                | LCSC C82942                                           |
| Аккумулятор          | LiPo 103450, 2000 мА·ч, с PCM                | типоразмер 10×34×50 мм                                |
| Накопитель           | microSD 32 ГБ Class 10 + push-push держатель | промышленная серия — опция для −20...+85 °С           |
| Индикация            | WS2812B-2020                                 | один RGB-светодиод состояния                          |
| Разъёмы              | USB Type-C 16P (заряд/сервис), пого-пады ×4  | док: 5 В + GND + 2 резерва (UART для диагностики)     |
| Прошивка             | ESP-IDF 5.x + libopus fixed-point            | Opus 16 кГц mono 24 кбит/с, complexity 0–2            |

## Приложение Б. Цены и бенчмарки: источники (проверено 17.08.2026)

| Факт                                    | Значение                                 | Источник                                                                                                                              |
|-----------------------------------------|------------------------------------------|---------------------------------------------------------------------------------------------------------------------------------------|
| Выделенный сервер RTX 4090              | от 56 900 ₽/мес                          | <a href="https://selectel.ru/services/gpu">selectel.ru/services/gpu</a> (офиц. прайс)                                                 |
| RTX 4090 почасово                       | 82.76 ₽/ч (59 587 ₽/мес)                 | <a href="https://immers.cloud/gpu/4090">immers.cloud/gpu/4090</a> (офиц.)                                                             |
| VPS с RTX 4090                          | ~29 000 ₽/мес                            | обзор <a href="https://aillist.ru">aillist.ru</a> 07.2026 (HOSTKEY)                                                                   |
| Облачный L4 24 ГБ                       | от 69.88 ₽/ч                             | <a href="https://selectel.ru/services/gpu">selectel.ru/services/gpu</a>                                                               |
| A100 80 ГБ в РФ                         | 212–317 ₽/ч                              | <a href="https://immers.cloud">immers.cloud</a> ; <a href="https://cloud.ru">cloud.ru</a> тарифы 11.08.2026                           |
| S3 standard / cold                      | 2.28–2.38 / 1.09–1.3 ₽/ГБ·мес            | прайс VK Cloud с 12.01.2026; cnews market (Selectel); docs Яндекса                                                                    |
| Managed PostgreSQL / BM 4 vCPU          | от 5 502 / от 5 838 ₽/мес                | <a href="https://toolfox.ru">toolfox.ru</a> 03.2026 (Яндекс Облако)                                                                   |
| WER GigaAM-v3 vs Whisper-v3 (телефония) | 17.4 vs 27.4; Golos Farfield 3.9 vs 16.4 | <a href="https://github.com/salute-developers/GigaAM">github.com/salute-developers/GigaAM</a> , <a href="#">evaluation.md</a> (офиц.) |
| Независимый бенчмарк русского ASR       | GigaAM2 8.42% avg — лучший открытый      | <a href="https://alphacephei.com/nsh/2025/04/18/russian-models.html">alphacephei.com/nsh/2025/04/18/russian-models.html</a>           |
| Скорость GigaAM (GPU, ONNX)             | RTF 0.033 (≈30× поток)                   | <a href="https://habr.com/ru/articles/1042574">habr.com/ru/articles/1042574</a>                                                       |



|                                    |                                                                                                                  |                                                                      |
|------------------------------------|------------------------------------------------------------------------------------------------------------------|----------------------------------------------------------------------|
| faster-whisper turbo batched       | 41× на L4; 70–100× на 4090                                                                                       | e2enetworks.com бенчмарк L4 2026; SYSTRAN/faster-whisper             |
| T-one стриминг                     | чанк 300 мс, эмиссия ~330 мс, пайплайн 1–1.2 с; WER колл-центр 8.63%                                             | github.com/voicekit-team/T-one; habr Т-Банка 07.2025                 |
| pyannote community-1               | DER: AMI 17.0, DIHARD-3 20.2; exclusive-режим                                                                    | huggingface.co/pyannote/speaker-diarization-community-1              |
| Silero VAD                         | MIT, <1 мс/чанк на CPU                                                                                           | github.com/snakers4/silero-vad                                       |
| SpeechKit / SaluteSpeech (ASR API) | ≈36 Р/ч; у Сбера мин. платёж 15 000 Р/мес                                                                        | developers.sber.ru тарифы (офиц.); своды по SpeechKit                |
| GigaChat API (юрлица, 15.07.2026)  | Lite 65/32.5, Pro 500/250, Max 650/325 Р/1М ток. (синхр./batch)                                                  | developers.sber.ru/docs/ru/gigachat/tariffs/legal-tariffs            |
| T-Pro 2.0 (32B, русский)           | файнтюн Qwen3-32B, гибридный резонинг                                                                            | habr.com/ru/companies/tbank/articles/928956                          |
| vLLM 32B AWQ на 4090               | ~65 ток/с decode; ≈180–300 разборов/GPU-ч                                                                        | gigagpu.com, databasemart.com бенчмарки 2026                         |
| ESP32-S3, Opus 16 кГц              | 4.9× RT @ c0 (fixed-point)                                                                                       | components.espressif.com / esp8266 micro-opus benchmark              |
| Потребление ESP32-S3               | modem-sleep 33–81 мА; Wi-Fi TX до 283 мА                                                                         | даташит ESP32-S3 v2.2, табл. 5-7...5-10                              |
| Компоненты бейджа                  | см. гл. 3.2                                                                                                      | живые тарифные сетки LCSC, 17.08.2026                                |
| Plaud NotePin / HiDock H1          | \$159 / \$269                                                                                                    | plaud.ai, hidock.com (офиц. магазины)                                |
| Сеть площадки                      | N100 26 900 Р; hAP ax <sup>2</sup> 12 490 Р; Keenetic 4G ~9 000 Р; SIM 700–1500 Р/мес                            | nezz.ru/DNS; mikrotik.ru; Я.Маркет; media.mts.ru                     |
| Правовая база                      | 152-ФЗ (ст. 6, 9, 11, 18, 21, 22), КоАП 13.11 (ред. 420-ФЗ), 233-ФЗ, ПП 1119, приказ ФСТЭК №21, ВС РФ 35-КГ16-18 | consultant.ru, garant.ru, разъяснения РКН; детальный разбор — гл. 10 |
| Курс                               | 82.6–83 Р/\$                                                                                                     | ЦБ РФ, середина августа 2026                                         |

Пометка о методе: цены собирались по официальным страницам провайдеров и производителей; там, где официальная страница недоступна роботу (капча у Яндексa), значение сверено по двум независимым вторичным источникам и помечено в тексте как оценка.

## Приложение В. Схема LLM-разбора (сокращённо)

```
{
  "conversation_id": "...",
  "schema_version": "1.3",
  "summary": "абзац: кто, что хотел, чем закончилось",
  "deal_stage_reached": "contact|needs|presentation|test_drive|objections|pricing|commitment",
  "outcome": "next_step_agreed|thinking|lost|purchased|no_sale_intent",
  "next_step": {"what": "...", "when": "2026-08-21", "confirmed_by_client": true},
  "objections": [
```

```

    {"type": "price|trade_in|credit|competitor|trust|timing|other",
      "quote_t0": 1082.4, "text": "дороже, чем в X",
      "handled": true, "handling_quality": 1..5, "handling_quote_t0": 1104.0}
  ],
  "commitments_by_manager": [{"what": "КП по кредиту", "due": "...", "t0": 811.2}],
  "checklist": [{"item": "спросил про трейд-ин", "done": false}],
  "scores": {"needs_discovery": 1..5, "presentation": 1..5, "objection_handling": 1..5,
    "closing": 1..5, "compliance_notice_given": true},
  "risk_flags": ["hot_client_no_next_step", "competitor_mentioned_3x"],
  "entities_for_matching": {"client_name": "...", "phone_last4": "...", "car_model": "...",
    "trade_in_model": "..."},
  "special_category_spans": [{"t0": 51.0, "t1": 58.5, "reason": "health"}] // к вырезанию
}

```

Каждый содержательный факт несёт таймкод-якорь (t0) — проверка по аудио в один клик. Поле `special_category_spans` обслуживает юридическое требование гл. 10.