

ТЕСТОВОЕ ЗАДАНИЕ · АРХИТЕКТУРНЫЙ ТРЕК

Система аналитики живых разговоров в дилерском центре

Проектирование системы целиком: захват звука в шоуруме, разбор разговоров, доведение результата до CRM и руководителя отдела продаж; второй этап — подсказки менеджеру в реальном времени

Автор: Илья

5 площадок · 100 менеджеров · горизонт 1000

Бюджет: $\leq \$100$ CAPEX и $\leq \$15/\text{мес}$ OPEX на менеджера

Все цены проверены по открытым источникам, август 2026 · курс 83 ₽/\$

Расчётная модель и работающий PoC пайплайна:

github.com/dadgrand/dealer-voice-analytics

Резюме решения

Как это устроено. Каждый менеджер носит бейдж-рекордер собственной разработки (ESP32-S3, два MEMS-микрофона, microSD, Opus-кодирование на борту; BOM $\approx$ \$52 при тираже 100 шт и $\approx$ \$31 при 1000 шт). Бейдж пишет звук всю смену и ни о чём не просит менеджера: снял с док-станции — запись пошла, поставил обратно — данные выгрузились, устройство заряжается. Близко расположенный микрофон решает сразу две главные проблемы шумного шоурума — отношение сигнал/шум и разделение голосов: голос менеджера всегда доминирует в его собственном бейдже, поэтому роли «менеджер/клиент» определяются по асимметрии каналов, а не по хрупкой слепой диаризации. На каждой площадке стоит свой шлюз (мини-ПК с собственной Wi-Fi-точкой и LTE-каналом) — система *вообще не зависит* от Wi-Fi дилера. Обработка — в российском облаке (требование 152-ФЗ): распознавание открытой моделью GigaAM-v3, дочистка диаризации ruannotate, LLM-разбор каждого разговора в структурированный JSON (этапы, возражения, чек-лист), результат — карточкой в самописной CRM и дашбордом для РОПа.

Сколько это стоит. CAPEX — **\$98 на менеджера** при 100 менеджерах (бейдж \$52 + ЗИП + док + доля шлюза) и **\$75** при 1000 — в бюджете \$100. OPEX — **\$11.7/мес** на менеджера при 100 и **\$8.9** при 1000 в консервативном сценарии (при оптимистичных, но реалистичных допущениях — \$7.4 и \$3.7) — в бюджете \$15 с запасом. Ключевые решения, которые удерживают экономику: self-hosted ASR вместо облачных API распознавания (те стоили бы $\sim$ \$28/мес на менеджера — вдвое больше всего бюджета), аренда GPU класса RTX 4090 в РФ от 40–83 ₽/час и LLM-разбор ночным батчем на тех же GPU.

Почему это будет полезно. РОП впервые видит, что происходит в разговорах: какие возражения системно не отрабатываются, на каком этапе теряются сделки, кого чему учить — не по самоотчётам менеджеров, а по фактическим диалогам. При марже дилера 50–150 тыс. ₽ с автомобиля системе достаточно приносить площадке *один* дополнительный проданный автомобиль раз в четыре месяца, чтобы окупаться; реалистичная цель — +1–2 п.п. к конверсии шоурум→сделка за счёт работы с возражениями и таргетного обучения (подробный расчёт — в гл. 12).

\$98 / \$75

CAPEX на менеджера (100 / 1000), бюджет \$100

\$11.7 / \$8.9

OPEX в мес (100 / 1000, консервативно), бюджет \$15

$\approx$ 1.8 с

задержка подсказки на этапе 2 (цель $\leq$ 3 с)

0 кнопок

действий менеджера для записи смены

Содержание

Резюме решения	2
1. Постановка задачи, модель нагрузки, допущения	4
2. Ключевые архитектурные решения	6
3. Хардвер: бейдж, док-станция, площадочный шлюз	8
4. Аудиотракт и разделение голосов	12
5. Облачная архитектура и стек	14
6. Пайплайн: путь данных от микрофона до CRM	16
7. CRM-модуль	18
8. Расчёты	20
9. Этап 2: подсказки в реальном времени	23
10. Надёжность, безопасность, право	26
11. Внедрение и человеческий фактор	28
12. Почему это будет полезно: модель ценности	30
Приложение А. BOM бейджа: партномера	32
Приложение Б. Цены и бенчмарки: источники	32
Приложение В. Схема LLM-разбора	33

1. Постановка задачи, модель нагрузки, допущения

1.1. Что строим

Сеть дилерских центров: 5 площадок, ~20 менеджеров на каждой. Менеджер проводит 5–8 живых разговоров с клиентами за смену, по 15–40 минут. Требуется: *этап 1* — захватывать разговоры в шоуруме, превращать в структурированный разбор и доводить до CRM и РОПа; *этап 2* — подсказки менеджеру в реальном времени. Ограничения: шумное открытое пространство, перемещения между машинами; Wi-Fi есть, но нестабильный и чужой; менеджеры — не технари и саботируют лишние действия; бюджет — до \$100 на железо на менеджера одновременно и до \$15/мес на облако и обработку; горизонт роста — 1000 менеджеров.

1.2. Модель нагрузки

Параметр	Значение	Комментарий
Разговоров за смену на менеджера	6.5 (5–8)	середина диапазона из ТЗ
Средняя длительность разговора	27 мин (15–40)	середина диапазона из ТЗ
Аудио разговоров за смену	$6.5 \times 27 \approx 2.9$ ч	на менеджера
Смен в месяц	22	график 5/2 либо 2/2 с ротацией — уточнить
Аудио в месяц на менеджера	64.3 ч	2.92×22
Доля речи в аудио разговора	0.70	паузы, осмотр машины; после VAD
Пиковый час (суббота)	60% менеджеров говорят одновременно	консервативно; см. гл. 8
Битрейт хранения	Opus 24 кбит/с, 16 кГц, моно-микс + метаданные каналов	10.5 МБ/ч; достаточно для ASR (гл. 4)

Суммарно: 100 менеджеров генерируют **~292 ч аудио разговоров в сутки** (~205 ч чистой речи), 1000 менеджеров — ~2 925 ч. Это определяет размер вычислительного парка (гл. 8).

1.3. Явные допущения

- Смена ≤ 11 часов — от этого считается батарея бейджа (гл. 3).
- Один менеджер ведёт разговор с одним клиентом (парой клиентов); групповые экскурсии — вне скоупа качества диаризации, но записываются.
- CRM у заказчика самописная — значит, интеграционный контракт и модель данных задаём мы (гл. 7), а не подстраиваемся под чужой API.
- Юрисдикция — РФ: персональные данные обрабатываются только на территории РФ (гл. 10); цены на облако — российские провайдеры.

- Тест-драйвы (разговор в машине) — записываются тем же бейджем; это даже более ценные разговоры. Шумовой профиль другой (дорога), деградация WER допустима.

1.4. Вопросы заказчику

Задание поощряет формулировать вопросы при нехватке данных. Ответы уточняют расчёты, но не меняют архитектуру — она устойчива к разбросу этих параметров:

1. График смен и часы работы площадок? (влияет на окно ночного LLM-батча и профиль пика)
2. Какая доля значимых разговоров происходит *вне* зоны Wi-Fi площадки — тест-драйвы, выездные показы? (влияет только на задержку доставки разбора, не на полноту)
3. Текучка менеджеров в год? (провижининг бейджей, объём ЗИП)
4. Есть ли на площадках проводной интернет, который можно арендовать под шлюз? (LTE тогда станет резервом — надёжнее и дешевле)
5. Требования СБ дилера: допустимо ли хранить аудио 6 месяцев, кто имеет право слушать записи, нужен ли on-premise вариант? (гл. 10)
6. Записываются ли сейчас телефонные звонки (колл-трекинг)? Если да — сопоставление визита с предшествующим звонком усилит связку с CRM (гл. 7)
7. Методология продаж (этапы воронки, скрипты, чек-листы), принятая в сети? Разбор LLM настраивается под неё (гл. 6); если формализованной нет — предложим стартовую.
8. Планируемая политика в отношении менеджеров: «записи для обучения» или «записи для контроля»? От этого зависит приживаемость (гл. 11) — рекомендуем первое.

2. Ключевые архитектурные решения

Шесть решений определяют всю систему. Каждое принято на пересечении ограничений задачи — шум, перемещения, чужой Wi-Fi, саботаж, \$100/\$15 — а не по отдельности.

Решение	Отвергнутые альтернативы и почему
Д1. Захват звука: носимый бейдж собственной разработки ESP32-S3, 2 MEMS-микрофона, microSD, Orus на борту. Микрофон в 20–25 см ото рта менеджера.	Потолочные/зонные микрофонные массивы — разговор перемещается между машинами и уходит на улицу/в тест-драйв; в открытом зале массив ловит смесь соседних разговоров и вентиляции (расстояние до рта 2–4 м против 0.2 м у бейджа — это –20...–26 дБ прямого сигнала); стоимость покрытия зала выходит за бюджет; юридически это запись «всех подряд», а не участников сделки. Смартфон менеджера — в кармане даёт глухой звук; «достань и положи на стол» — действие, которое саботируют; BYOD неуправляем; корпоративный смартфон не влезает в \$100. Готовые AI-рекордеры (Plaud NotePin \$159, HiDock \$169–269) — дороже бюджета до всякой инфраструктуры, закрытая прошивка, привязка к чужому облаку (нарушение 152-ФЗ), нет док-станций и fleet-управления. Китайские OEM-бейджи (\$15–40 оптом) — рассматриваем как план Б для пилота (гл. 3.6).
Д2. Сеть: своя инфраструктура на площадке Собственная Wi-Fi AP + шлюз (мини-ПК) + LTE-аплинк. Wi-Fi дилера не используется вовсе.	«Работать через Wi-Fi дилера» — сеть чужая, нестабильная и не под нашим контролем: это прямое ограничение ТЗ, а не гипотеза. Любая архитектура, у которой от чужого Wi-Fi зависит сохранность данных, развалится в эксплуатации. У нас чужая сеть может быть лишь резервным аплинком шлюза. «Бейджи с LTE-модемом каждый» — +\$15–20 к BOM, +SIM на каждого, ×3 к энергопотреблению — незачем, когда данные не realtime-критичны (этап 1) и есть точка гарантированной выгрузки — док.
Д3. Разделение голосов: асимметрия каналов + лёгкая диаризация «Кто говорит» решается физикой: голос менеджера всегда громче в его собственном бейдже. ruannote только подчищает дальнюю речь.	Слепая диаризация одноканальной записи — в шумном зале с соседними разговорами DER 20–25% даже у SOTA-моделей; ошибка в ролях обесценивает разбор («клиент возражал» ↔ «менеджер возражал»). Идентификация по голосовым профилям (voice-ID) — юридически переквалифицирует данные в биометрию (ст. 11 152-ФЗ): письменные согласия, УЗ-1/УЗ-2, штрафы за утечку 15–20 млн ₽. Запрещаем архитектурно (гл. 10).
Д4. Обработка: батч в облаке РФ, self-hosted модели ASR GigaAM-v3 + ruannote + LLM T-Pro 2.0 на арендных GPU класса RTX 4090; локально на устройстве — только VAD-гейтинг и Orus.	Облачные ASR API (SpeechKit, SaluteSpeech ≈ 36 ₽/ч) — 64 ч/мес × 36 ₽ ≈ 2 300 ₽ ≈ \$28/мес на менеджера: одна транскрибация съедает два бюджета. Отпадает арифметически (гл. 8). Зарубежные API — нарушение локализации 152-ФЗ. Обработка на краю (шлюзе) — N100 без GPU тянет VAD и упаковку, но не ASR 292 ч/сутки; GPU на каждой площадке дороже и сложнее в обслуживании, чем централизованный парк. ASR на бейдже — на ESP32 нереально (нужен ~GPU-класс).

Д5. CRM: свой модуль в самописной CRM заказчика Проектируем модель данных, API-контракт и UI-модуль «Разговоры» как часть CRM (гл. 7).	Интеграция «сбоку» через универсальные коннекторы — не с чем интегрироваться: CRM самописная. Это преимущество: контракт задаём мы, сопоставление разговор→сделка получает нативную поддержку (календарь визитов, автосоздание лидов, подтверждение одним тапом), а не «запись в примечания».
Д6. UX менеджера: ноль действий Снял с дока — пишет; поставил — выгрузилось и заряжается. Один светодиод. Одна кнопка — «пауза 10 минут». Подтверждение сделок — 5–8 карточек в Telegram, 1 минута в день.	Любой UX со «включи запись» — менеджеры «забудут» включать: это прямое ограничение ТЗ («саботируют всё, что усложняет им день»). Полнота записи должна достигаться по умолчанию, а не дисциплиной. Метрика приживаемости — % записанных смен — видна РОПу (гл. 11).




Рис. 1. Архитектура системы: площадка → облако РФ → CRM/РОП. Пунктир — контуры этапа 2.

Дальше документ раскрывает каждое решение: железо (гл. 3), аудиотракт (гл. 4), облако (гл. 5), пайплайн (гл. 6), CRM (гл. 7), расчёты (гл. 8), этап 2 (гл. 9), надёжность и юридику (гл. 10), внедрение (гл. 11), пользу (гл. 12).

3. Хардвер

Носимых устройств три класса: бейдж-рекордер (по числу менеджеров), док-станции и площадочный шлюз. Вся электроника — из серийных компонентов с открытых складов (LCSC/JLCPCB); цены проверены 17.08.2026 по живым тарифным сеткам и помечены в приложении Б источниками.

3.1. Бейдж-рекордер: конструкция




Рис. 2. Блок-схема бейджа. Красные связи — силовые, чёрные — данные.

Форм-фактор: бейдж 95×65×12 мм на магнитной клипсе/шнурке, носится на груди вместо обычного именного бейджа (им же и является — печатная вставка с именем). Ориентация фиксирована клипсой: микрофон №1 смотрит вверх, в сторону рта носителя, №2 — фронтально, на собеседника. Вес ~90 г. Никаких экранов: RGB-светодиод и вибромотор не ставим — лишние цена/энергия (индикация — светодиод, статус — в Telegram-боте и на доке).

Выбор SoC — ESP32-S3 (модуль ESP32-S3-WROOM-1-N16R8, \$3.62 @100). Требования к чипу: два цифровых микрофона по I2S, кодирование Opus в реальном времени, файловая система на microSD, Wi-Fi для выгрузки, низкое потребление, зрелый SDK. ESP32-S3 закрывает всё: I2S-контроллер в std-режиме принимает два MEMS-микрофона как стерео (выбор канала пином WS); замер опубликованного порта Opus (fixed-point, Xtensa-DSP) даёт на 240 МГц **4.9× реального времени** при complexity 0 для 16 кГц моно — то есть кодек занимает ~20% одного ядра, второе остаётся ОС и файловой системе. Альтернатива nRF5340 (BLE-флагман Nordic, \$5.22) отвергнута: без Wi-Fi выгрузка ~50 МБ смены по BLE занимает часы — док-архитектура с ним не работает.

Выбор микрофонов — 2× TDK ICS-43434 (\$2.78 @100 каждый). Цифровой I2S-выход (24 бита) — аналоговый тракт и его наводки исключаются по построению. SNR 64 дБА — верх класса MEMS; AOP 120 дБ SPL — не клипует, даже если менеджер говорит громко в 20 см от капсуля. Рассматривались: INMP441 — фактически EOL (в серию закладывать нельзя), MSM261S4030H0 — дешевле, но SNR 57 дБА, экономия ~\$2 не стоит потери 7 дБ на шумном объекте. Акустика корпуса: капсули за мембранами Gore-типа (ветрозащита, IP54 передней панели), порты разнесены на 40 мм и развязаны резиновыми демпферами от корпуса (структурный шум одежды).

Питание. Энергобюджет режимов (по даташиту ESP32-S3 v2.2 и типовым значениям SD):

Режим	Ток @3.7 В	Доля смены
Запись: I2S + Orus (80–160 МГц) + буферизация RAM, Wi-Fi выкл.	45–70 мА	~85%
+ сброс буфера на microSD (бёрсты раз в ~30 с)	+15–100 мА на <1 с	~2%
Wi-Fi выгрузка сегментов (TX до 283 мА пик)	~120 мА средний	~3%
Тишина: light-sleep с VAD-пробуждением	~2–5 мА	~10%

Средневзвешенно $\approx 55\text{--}75$ мА $\rightarrow$ смена 11 ч $\approx$ **600–830 мА·ч**. Аккумулятор LiPo 103450 **2000 мА·ч** (\$2.06) даёт запас $>2\times$: устройство доживает до конца смены и через два года деградации до 80% ёмкости, и при «забыл поставить в док» переживает вторую смену. Зарядка — BQ24074 (\$1.40): выбран из-за power-path (бейдж работает и выгружает данные, стоя в доке на зарядке — дешёвый TP4056 этого не умеет); MAX17048 (\$1.57) отдаёт честный процент батареи в телеметрию — «менеджер Иванов третий день не ставит бейдж в док» виден РОПу.

Хранение. microSD 32 ГБ (\$2.02). Смена в Orus 24 кбит/с ≈ 50 МБ — карта вмещает месяцы; фактическая политика — кольцевой буфер и удаление сегмента после подтверждённой загрузки в облако (по хэшу). eMMC отвергнут: дороже и превращает замену носителя в пайку. Сегменты по 5 минут: атомарная единица выгрузки/ретрая; каждый шифруется AES-GCM ключом устройства (ключи — в eFuse, разговор невозможно прочитать с украденной карты) и подписывается (badge_id, seq, t_0 , t_1 , RMS-профили обоих каналов для канального приора диаризации).

Прошивка (ESP-IDF/FreeRTOS), конечный автомат: «в доке» (зарядка, полная выгрузка, OTA по подписанным образам, самотест микрофонов) $\rightarrow$ «ношение: тишина» (light-sleep, энергетический VAD будит) $\rightarrow$ «ношение: речь» (запись+Orus) $\rightarrow$ «деградация» (SD-ошибка/батарея $<10\%$ — красный светодиод, телеметрия). Часы синхронизируются NTP от шлюза при каждом контакте; дрейф RTC между синхронизациями $<\pm 2$ с/сутки — достаточно для сопоставления с CRM. Единственная кнопка — «пауза 10 минут» (личный разговор): пауза логируется как событие, злоупотребление видно в статистике полноты записи.

3.2. BOM и себестоимость

Позиция	Компонент	@100 шт, \$	@1000 шт, \$
SoC-модуль	ESP32-S3-WROOM-1-N16R8	3.62	3.40
Микрофоны $\times 2$	TDK ICS-43434	5.56	5.23
Накопитель	microSD 32 ГБ + держатель	2.32	2.05
Аккумулятор	LiPo 103450, 2000 мА·ч, PCM	2.06	1.96
Зарядка/учёт	BQ24074 + MAX17048 + LDO ME6211	3.00	2.51
Разъёмы/индикация	USB-C, WS2812B, кнопка, пого $\times 4$	0.55	0.45
Пассив	~30 позиций, ESD, ферриты	1.50	1.20
Плата и монтаж	JLPCB, 2 слоя, 50 $\times$ 90 мм	4.50	3.00

Корпус	@100: MJF-печать · @1000: литьё (форма ~\$2 000 амортизирована)	18.00	4.50
Сборка	финальная сборка, прошивка, тест, упаковка	4.00	2.50
Итого BOM		≈45	≈27
+15% (брак, логистика, пошлины)		≈52	≈31

Ценовой риск при тираже 100 — корпус (MJF-печать даёт до трети себестоимости); резерв — вакуумное литьё в силикон (~\$8–10/шт на 100 шт) или запуск пресс-формы уже на пилотной партии, если решение о масштабировании принято. Реалистичность цен подтверждается рынком: китайские OEM-бейджи-рекордеры сопоставимой начинки продаются по \$15–40 оптом; Plaud NotePin (\$159) продаёт не железо, а подписку на софт.

3.3. Док-станция

Мульти-док на 10 мест (на площадку — два): наклонные слоты с пого-контактами (5 В, до 1 А на слот), БП 60 Вт, монтаж на стойке ресепшн/в комнате менеджеров. Вся логика в бейдже — док максимально глуп и дешёв (~\$120 за 10-местный в мелкой серии, референс — зарядные станции раций). Постановка в док — механический триггер конца смены: полная выгрузка остатков, зарядка, ОТА. Съём — старт записи и привязка «бейдж→менеджер» (менеджер берёт любой заряженный бейдж, тапнув по нему картой-пропуском/выбрав себя в Telegram-боте — двух вариантов достаточно, выбираем на пилоте; жёсткая персонализация бейджей проще, но умирает на подменах и забытых устройствах).

3.4. Площадочный шлюз



Рис. 3. Сеть площадки. Чужой Wi-Fi — только пунктирный резерв.

Шлюз — мини-ПК Intel N100/16 ГБ (26 900 Р): приём сегментов от бейджей через собственную точку доступа MikroTik hAP ax² (12 490 Р; отдельный SSID, WPA3, изолированный VLAN до шлюза), буфер на 7 дней (~1 ГБ/сутки с площадки), дедупликация, сборка смен, WireGuard/mTLS-туннель в облако, NTP для бейджей, кэш ОТА-образов, fleet-агент. Аплинк — LTE-роутер Keenetic Runner 4G (~9 000 Р) с SIM 35–150 ГБ (700–1500 Р/мес; трафик площадки ≈ 30 ГБ/мес); проводной интернет дилера, если дают

порт, — резерв (или наоборот: провод основной, LTE резерв — по площадке). На этапе 2 шлюз получает вторую роль: локальный детектор триггеров и быстрый путь подсказок (гл. 9) — N100 тянет это на CPU (T-one — 71.6М параметров, работает от 4 ядер).

3.5. CAPEX на менеджера

Статья	@100, \$	@1000, \$
Бейдж (BOM + 15%)	52	31
ЗИП-фонд бейджей 10%	5	3
Док-станция (доля слота)	12	12
Шлюз+AP+LTE-роутер (÷20 менеджеров)	29	29
Итого (бюджет \$100)	≈98	≈75

При 100 менеджерах — на грани бюджета: резервы — корпус (–\$8), совмещение LTE-роутера со шлюзом (USB-модем, –\$5) и трактовка сетевой обвязки площадки как инфраструктурного, а не «поголовного» CAPEX. При 1000 — комфортный запас 25%.

3.6. План Б по железу (снятие риска разработки)

Собственный бейдж — 3–4 месяца до серийной партии (EVT→DVT→PVT). Чтобы не задерживать пилот и снять риск «железо не успело», параллельно закупается 10–20 китайских OEM бейджей-рекордеров (\$25–40) с записью на карту: они не умеют Wi-Fi-выгрузку и Orus, выгрузка через док-ридер на шлюзе, качество хуже — но пилотный поток данных и разработка облачной части стартуют в первый месяц. Прошивочный и облачный контракты совпадают, замена парка прозрачна.

3.7. Жизненный цикл парка (1000 устройств)

- **Провижининг:** на производстве в eFuse зашивается ключ устройства и серийник; активация — сканированием QR при поступлении на площадку; привязка к площадке автоматическая по первому контакту со шлюзом.
- **ОТА:** подписанные образы, staged-роллаут (1 площадка → 10% → все), откат по watchdog. Обновления — только в доке ночью.
- **Мониторинг флота:** батарея, ошибки SD, последняя выгрузка, % записанных смен — на дашборде; алерт РОПу и в саппорт при «бейдж молчит >24 ч».
- **RMA:** ЗИП 10% на площадке; замена = взять другой бейдж из дока (привязка не жёсткая); дефектные — почтой на базу, диагностический лог на SD.
- **Сертификация:** декларация соответствия ЕАЭС (ТР ТС 020/037), нотификация ФСБ на шифрование в составе устройства (типовая для Wi-Fi+AES изделий); закладываем 2 месяца и ~200 тыс. ₽ в NRE (не в поштучный CAPEX).

4. Аудиотракт и разделение голосов

4.1. Почему близкий микрофон побеждает шум физикой

Уровень прямого сигнала падает на 6 дБ с удвоением расстояния. Рот менеджера от его бейджа — 20–25 см; от потолочного массива — 2.5–4 м: разница **20–26 дБ** в пользу бейджа ещё до всякой обработки. Диффузный шум зала (вентиляция, соседние разговоры, шаги) при этом одинаков для обоих. На практике это переводит задачу из класса «далёкий микрофон в кафе» (WER 30–50%) в класс «гарнитура/телефония» (WER 9–17% у выбранной модели, см. 4.4). Второй микрофон бейджа, направленный фронтально, держит клиента на дистанции 0.5–1.5 м — хуже, чем канал менеджера, но радикально лучше любого стационарного варианта, и его сигнал усиливается тем, что клиент в диалоге почти всегда обращён к менеджеру.

4.2. Что считается на бейдже, что дальше

На устройстве — только дешёвое и необратимое: энергетический VAD-гейтинг (не пишем тишину), Opus 24 кбит/с (16 кГц моно-микс двух каналов + покadresовые RMS/спектральные метрики каждого канала в метаданных сегмента — 40 байт/с, они питают диаризацию), AES-GCM. Никакого шумоподавления на бейдже: необратимая обработка до ASR только вредит (модели обучены на сыром звуке), а вычислительно нейросетевой денойз ESP32 не тянет. Всё умное — в облаке, где его можно менять без перепрошивки парка.

4.3. Диаризация: двухступенчатая схема

Ступень 1 — канальный приор (почти бесплатно, CPU). Для каждого 20-мс кадра сравниваем энергию/спектральный наклон каналов «вверх» (рот носителя) и «фронт». Голос носителя даёт устойчивую разницу +12...+20 дБ в «своём» канале — сегменты «говорит менеджер» выделяются порогово с точностью, недостижимой для слепой диаризации, и *это не биометрия*: мы используем геометрию микрофонов, а не голосовой профиль личности (юридическая граница — гл. 10). Остаток — «дальняя речь»: клиент, второй клиент, соседний разговор, объявления по залу.

Ступень 2 — кластеризация дальней речи (GPU, только по нужным кускам). ruannote community-1 (CC-BY-4.0; DER на AMI 17.0%) в режиме exclusive-сегментации дочищает дальнюю речь: отделяет основного собеседника (стабильно громкий и чередующийся с менеджером) от фонового чужого разговора (не согласован по тайм-тейкингу, тише, прерывист). Эмбединги кластеризуются *внутри одного разговора* и уничтожаются после сегментации — межразговорная привязка «этот же клиент» по голосу не делается (снова граница биометрии). Выход: разметка РОЛЬ ∈ {менеджер, клиент(ы), фон} с таймкодами; фон в транскрипт не попадает.

Перекрытия (говорят одновременно — в живом споре до 15–20% времени): канальный приор работает и в перекрытии (у каждого источника свой доминантный канал), поэтому реплики менеджера восстанавливаются всегда; неразборчивые куски клиента помечаются low-confidence и не порождают «галлюцинированных» цитат в разборе (LLM получает confidence).

4.4. Выбор ASR: сравнение на русской спонтанной речи

Модель	Лицензия	WER: телефония / callcenter / дальнее поле	Скорость (GPU)	Вердикт
--------	----------	--	----------------	---------

GigaAM-v3 RNNT (Сбер, 220M)	MIT	17.4 / 9.5 / 3.9 (Golos Farfield)	RTF 0.033 (≈30× поток; ~100×+ на 24 ГБ агрегированно)	выбор для батча
Whisper large-v3 (-turbo)	MIT	27.4 / ~19 / 16.4	41× (L4, batched) – 70–100× (4090)	хуже в 1.5–2× на нашем типе речи; резерв для мультязычности
T-one (Т-Банк, 71.6M)	Apache 2.0	6.2–8.6 (телефония) / 8.63 / —	стриминг, чанк 300 мс; CPU-ок	выбор для этапа 2 (стриминг); в батче уступает GigaAM на неспонтанных доменах
Vosk 0.54	Apache 2.0	avg 10.7 по 12 сетам	стриминг CPU	резерв для полностью офлайн-шлюза
NeMo Parakeet v3	NVIDIA OML	16.0 avg (ru)	239× (L4)	быстрый, но качество на русском не конкурент

Числа — официальные evaluation-таблицы GigaAM/T-one и независимый бенчмарк alphacephei (12 русских датасетов); источники в приложении Б. Выбор GigaAM-v3 — это 1.5–2 кратное преимущество по WER на именно нашем классе звука (спонтанная речь, шум, дальнее поле для канала клиента) при MIT-лицензии и пригодной скорости. Модель 220M легко влезает в 4–6 ГБ VRAM — на одной RTX 4090 работают несколько воркеров параллельно.

4.5. Сегментация смены на разговоры

Смена — непрерывный поток с дырами тишины. «Кандидат разговора» строится на шлюзе/в облаке: Silero VAD (MIT, CPU, <1 мс на кадр) собирает речевые интервалы; границы разговора — тишина >3 мин, исчезновение дальнего собеседника >5 мин при продолжающейся речи менеджера (закончил с клиентом, говорит с коллегами — фильтруется на ступени диаризации), постановка в док. Куски 15–40 мин с чередованием «менеджер ↔ дальний голос» — кандидаты; куски без чередования (совещание, обед) помечаются «не разговор с клиентом» и не анализируются LLM — экономия и приватность одновременно. Ошибка склейки двух клиентов в один разговор чинится на шаге сопоставления с CRM (гл. 7): менеджер видит карточку «2 клиента?» и делит одним тапом.

4.6. Ожидаемое качество и деградационные режимы

- Канал менеджера: WER ~9–12% — достаточно для надёжного разбора аргументации менеджера.
- Канал клиента: WER ~15–25% в зале; смысловые единицы (возражения, имена, модели) LLM восстанавливает из контекста; confidence прокидывается до разбора и до UI (сомнительные цитаты подсвечены).
- Тест-драйв: дорожный шум — WER клиента до ~30%; факт и тематика разговора сохраняются.
- Мусорные сегменты (музыка, объявление, ветер) — отбрасываются VAD+диаризацией до ASR, GPU не тратится.
- Контроль качества постоянный: 1% разговоров в неделю — выборочная ручная оценка WER/DER разметчиком (≈3 ч работы на 100 менеджеров), тренд — на дашборде качества (гл. 5).

5. Облачная архитектура и стек

5.1. Размещение

Всё, что касается персональных данных (аудио, транскрипты, разборы), живёт в российском облаке — это не предпочтение, а ч. 5 ст. 18 152-ФЗ (гл. 10). Основной контур — Selectel (выделенные GPU дешевле рынка, S3 2.29/1.14 ₽/ГБ, сегмент «облако 152-ФЗ» до УЗ-1) с почасовым бурстом GPU в immers.cloud; равноценные альтернативы — Яндекс Облако/VK Cloud (сводная таблица цен — приложение Б). Мультиклауд не городим: на нашем масштабе это усложнение без пользы, переезд страхует тем, что весь стек — открытый софт в контейнерах поверх S3-совместимого API и PostgreSQL.

5.2. Стек и обоснование

Слой	Выбор	Почему (и что отвергнуто)
Сервисы API/ingest	Go	дешёвые по CPU/RAM статически слинкованные сервисы, простая поставка; Python оставлен ML-воркерам, где экосистема решает
ML-воркеры	Python (onnxruntime/CTranslate2, vLLM)	родная среда GigaAM/pyannote/T-Pro; изоляция в контейнерах по типам задач
Очередь	NATS JetStream	лёгкая (один бинарь), персистентная, ack/retry/DLQ. Kafka отвергнута: managed-кластер от 13.4 тыс. ₽/мес и операционный вес ради потока в сотни сообщений/мин не оправданы; при 10× росте миграция тривиальна (интерфейс «очередь заданий»)
БД	Managed PostgreSQL (+pgvector)	транскрипты JSONB, разборы, флот, идемпотентность; pgvector закрывает семантический поиск по разговорам без отдельного векторного хранилища. ClickHouse отложен до масштаба 1000+ (агрегаты пока тривиальны для PG)
Объектное хранилище	S3-совместимое (Selectel/Яндекс)	аудио: standard 1 мес → cold, TTL 6 мес (лайфцикл-политики); 2.3/1.1 ₽/ГБ·мес
Оркестрация	Docker Compose на BM (100 mpr) → Managed K8s (300+)	на 100 менеджерах хватает 2 BM + GPU-нод; K8s-мастер и обвязка — когда парк GPU станет автоскейлиться (гл. 8)
ASR / диаризация / LLM	GigaAM-v3 · pyannote community-1 · T-Pro 2.0 32B AWQ (vLLM)	обоснование — гл. 4 и 6; все лицензии позволяют коммерческое использование (MIT / CC-BY-4.0 / Apache 2.0-производная)
Наблюдаемость	VictoriaMetrics + Grafana + Loki, Sentry	лёгкий самостоятельный стек; три дашборда: флот, пайплайн, качество
Доступ устройств	WireGuard-туннели шлюзов, mTLS для бейджей	устройство = identity-сертификат; отзыв при краже

5.3. GPU-парк: главный расчётный узел

Три задачи делят GPU класса RTX 4090 (24 ГБ): диаризация (дорогая: $RTF_x \approx 15$ консервативно), ASR ($RTF_x \approx 40$ консервативно с батчингом) и LLM-разбор (T-Pro 2.0 32B AWQ: $\sim 180\text{--}300$ разговоров в GPU-час). Днём приоритет у диаризации+ASR (свежие разговоры), LLM-очередь дожёвывается ночью — GPU загружены равномерно, покупать отдельный LLM-парк не нужно. Закупка гибридная: постоянная подписка (выделенный сервер 56 900 Р/мес Selectel / 29 000 Р HOSTKEY) под ровное основание нагрузки + почасовая аренда (82.76 Р/ч immers.cloud) под субботние пики и рост. Прерываемые инстансы (скидки до 75% у Selectel) — кандидат после пилота; батч-пайплайн переживает вытеснение по построению (задания идемпотентны, ретраи дешевы). Полные цифры по обоим масштабам — гл. 8.

5.4. Мониторинг как продукт, а не приложение

- **Флот:** % бейджей, вышедших на связь сегодня; % записанных смен (главная метрика приживаемости); батареи; очередь RMA. Алерты: «бейдж молчит 24 ч», «на площадке X доля записанных смен упала ниже 80%».
- **Пайплайн:** лаг очередей по стадиям (выгрузка→сегментация→ASR→LLM→CRM), SLA-таймер «разговор → карточка» (цель: 95% в тот же день), глубина ретраев, стоимость GPU-часа факт/план.
- **Качество:** WER-прокси (perplexity ASR, доля low-confidence), DER-выборки, доля разговоров без автосопоставления со сделкой (цель <15% после шага Б), доля отклонённых менеджерами сопоставлений.

6. Пайплайн: путь данных от микрофона до CRM

Путь данных: от микрофона до карточки в CRM (этап 1)




Рис. 4. Восемь шагов пайплайна этапа 1 с задержками и точками сопоставления.

6.1. Контракты данных по шагам

Шаг	Артефакт	Формат/ключи
Бейдж → шлюз	Сегмент 5 мин	Opus + AES-GCM; заголовок: badge_id, seq, t ₀ /t ₁ , RMS-профили каналов, хэш
Шлюз → облако	Тот же сегмент	батч-апплоад по WireGuard; ключ идемпотентности (badge_id, seq)
Сборка	Смена → кандидаты разговоров	shift_id; conversation_id = hash(badge, t ₀); границы по VAD/диаризации/доку
Диаризация+ASR	Транскрипт	JSONL: {t ₀ , t ₁ , role: mgr client bg, text, conf}; хранится в PG (JSONB), аудио — в S3
LLM-разбор	Analysis	строгий JSON по схеме (прил. В): этап сделки, возражения[{тип, отработано, цитата, t}], обязательства, чек-лист, оценки, сущности для матчинга
Сопоставление	Связь conversation↔deal	confidence + источник (А/Б/В); лог всех кандидатов
CRM	Карточка разговора	идемпотентный upsert по conversation_id; версия разбора

6.2. Надёжность доставки

Правило одно: **каждый следующий хоп подтверждает приём, предыдущий только после этого удаляет**. Бейдж хранит сегмент до ask шлюза (место позволяет держать недели); шлюз — до ask облака (7 дней буфера); в облаке сегмент немедленно попадает в S3, и только потом в очередь обработки. Все стадии идемпотентны по естественным ключам — повторная доставка/обработка безвредна, exactly-once достигается на уровне эффекта (upsert), а не транспорта. Ретраи с экспонентой и DLQ; застрявшее в DLQ видно на дашборде пайплайна. Потерять разговор можно единственным способом — физически утопить бейдж до контакта со шлюзом.

6.3. LLM-разбор: чем «структурированный разбор» является технически

Один вызов T-Pro 2.0 (32B, vLLM, guided JSON по схеме) на разговор: вход — транскрипт с ролями и confidence + профиль сделки из CRM (этап, модель, история) + методология продаж сети (конфигурируемый чек-лист этапов: контакт → выявление потребности → презентация → тест-драйв → работа с возражениями → деньги/трейд-ин/кредит → следующий шаг). Выход-схема (прил. В) написана так, чтобы каждый факт имел таймкод-якорь в транскрипте — РОП по клику слушает первоисточник, галлюцинации проверяемы за секунды. Второй, дешёвый проход (~8B или правила) — PII-маскирование транскрипта для долгого хранения и обучающих подборок (гл. 10). Промпт и схема версионизируются; изменение — A/B на золотом наборе из 50 размеченных разговоров (создаётся на пилоте, гл. 11).

6.4. Сопоставление разговор ↔ сделка (вопрос 3 задания)

Три ступени, каждая закрывает свою долю случаев; цифры-цели по данным пилота:

1. **Контекст (авто, ~60–70%).** Мы знаем менеджера (бейдж), время (запись) и площадку. В CRM у менеджера есть календарь визитов/тест-драйвов. Пересечение по времени однозначно → связка готова. Здесь окупается «свой CRM-модуль»: визиты — первоклассная сущность (гл. 7), и чем дисциплинированнее ведутся, тем выше автосопоставление — метрика этого тоже видна РОПу.
2. **Содержание (авто, +15–20%).** LLM извлекает из транскрипта имя клиента, телефон (клиент диктует при записи на тест-драйв), модель, трейд-ин → fuzzy-поиск по клиентам/сделкам менеджера и площадки за ± 30 дней. Порог уверенности консервативный: ложная связка вреднее несвязанного разговора.
3. **Подтверждение (менеджер, 1 минута в день).** В конце смены Telegram-бот показывает 5–8 карточек: «15:20–15:55, обсуждали X5 в trade-in — это Иванов И.? [Да] [Выбрать] [Новый клиент]». «Да» — один тап; «Новый клиент» — автосоздание лида с предзаполнением из транскрипта (имя, телефон, интерес) — менеджеру это экономит ручной ввод, поэтому шаг воспринимается как польза, а не контроль. Неподтверждённое остаётся в очереди РОПа.

Все связки логируются с источником и уверенностью; ошибочную РОП/менеджер разрывают в один клик, разрыв — обучающий сигнал для порогов матчинга.


6.5. SLA этапа 1

Разговор, закончившийся до 16:00, — карточка в CRM в тот же день; вечерние — к 9:00 следующего дня. Основная задержка — не вычисления (пиковый час 100 менеджеров парк разбирает за ≤ 2 ч, гл. 8), а доставка хвостов записи при слабом аплинке; поэтому шлюз выгружает сегменты с приоритетом «сегодняшнее раньше вчерашнего», а бейджи начинают выгрузку оппортунистически в течение дня, не дожидаясь дока.

7. CRM-модуль

CRM у заказчика самописная — проектируем расширение как её родной модуль: три новые сущности вокруг существующих «клиент/сделка», один экран в карточке сделки, один дашборд, один бот. Ниже — контракт, который отдаётся команде CRM.

Модель данных CRM-модуля (ядро)



Аудио и транскрипты — в контуре аналитики (S3+PG, УЗ-3); CRM хранит ссылки и разбор. Retention: аудио 6 мес, транскрипты 24 мес (маскированные).

Рис. 5. Модель данных: синее — организация/парк, фиолетовое — существующее ядро CRM, зелёное — новые сущности аналитики.

7.1. Что появляется в CRM

- **Карточка разговора в сделке:** хронология всех разговоров по сделке; в каждом — итог одним абзацем, этап, чек-лист (что сделано/пропущено), возражения со статусом отработки, обязательства («обещал КП до пятницы» — автозадача менеджеру), плеер с прыжками по транскрипту от каждого факта разбора.
- **Дашборд РОПа:** воронка по этапам разговоров (где реально теряются сделки, а не где менеджер отметил); топ неотработанных возражений недели («дорого» — 34 случая, отработано 12); рейтинг менеджеров по чек-листу; динамика; сигналы «сделка под риском» (негатив клиента + нет следующего шага). Из любой цифры — проваливание до конкретных разговоров и аудио.
- **CoachingTask:** паттерн ошибок менеджера (три подряд неотработанных «дорого») автоматически превращается в задачу на обучение с примерами-разговорами; прогресс виден по следующим разговорам этого менеджера — обучение замыкается в цикл.
- **Telegram-бот менеджера:** подтверждение сопоставлений (гл. 6.4), выбор бейджа при заступлении, «мой разбор дня» — краткая сводка собственных разговоров (менеджер получает пользу лично, не только контроль — критично для приживаемости).

7.2. API-контракт (аналитика → CRM)

Эндпоинт	Назначение
PUT /v1/conversations/{id}	идемпотентный upsert карточки разговора (статус: recorded→transcribed→analyzed→matched)

PUT /v1/conversations/{id}/analysis	разбор (версионизируемый JSON, прил. В)
POST /v1/conversations/{id}/match	предложение связки со сделкой {deal_id, confidence, source}
POST /v1/leads	автосоздание лида из неопознанного разговора
GET /v1/managers/{id}/visits?date=	календарь визитов для ступени А матчинга
GET /v1/deals/search?q=	fuzzy-поиск сделок для ступени Б
POST /v1/coaching-tasks	задача обучения из паттерна ошибок
WS /v1/alerts	сигналы «сделка под риском», алерты флота для РОПа

Аудио и сырые транскрипты в CRM не копируются: CRM хранит разбор и ссылки, плеер стримит из контура аналитики с проверкой прав (RBAC: менеджер слышит своё, РОП — свою площадку, HR/обучение — только обезличенные подборки). Это держит периметр персональных данных компактным (гл. 10) и не раздувает базу CRM.

7.3. Почему связка получается надёжной именно в своей CRM

Ключевая проблема «кусоч непрерывной записи ↔ сделка» — не алгоритмическая, а процессная: в чужой CRM визиты ведутся как попало, и матчить не с чем. В своей CRM мы делаем визит первоклассной сущностью с дешёвым вводом (запись на тест-драйв и так фиксируется), а недостающее закрываем однопоточным подтверждением менеджера, которое одновременно экономит ему ручное заполнение CRM (автолиды, автозадачи из обязательств). Так у всех трёх участников — алгоритма, менеджера, РОПа — совпадают стимулы, и доля сопоставленных разговоров растёт со временем (метрика на дашборде качества).

8. Расчёты

Все формулы приведены явно; цены — август 2026, источники в приложении Б; курс 83 ₽/\$. Расчёты продублированы скриптом (репозиторий проекта), сценарии: *консервативный* (нижние оценки скорости моделей, дорогой GPU-провайдер) и *оптимистичный* (верхние реалистичные оценки, дешёвый провайдер). Бюджету должен удовлетворять консервативный.

8.1. Поток аудио в пиковый час

Пик — суббота, день: одновременно говорят 60% менеджеров.

	100 менеджеров	1000 менеджеров
Одновременных разговоров	$100 \times 0.6 = 60$	600
Суммарный поток (Opus 24 кбит/с)	$60 \times 24 = 1.4$ Мбит/с	14.4 Мбит/с
На одну площадку (12 разговоров)	0.3 Мбит/с — на порядки ниже ёмкости LTE; сеть не является узким местом	
Аудио, порождённое пиковым часом	60 ч (42 ч речи)	600 ч (420 ч речи)

8.2. Параллельные обработчики

Скорости обработки на GPU класса RTX 4090 (обоснование — гл. 4; RTFx = часов аудио на GPU-час): ASR GigaAM-v3 — 40 (конс.) / 100 (опт.); диаризация ruannote с канальным приором — 15 / 50; LLM-разбор T-Pro 2.0 32B — 180 / 300 разговоров в GPU-час.

Суточная потребность, GPU-часов (100 менеджеров, консервативно): ASR: $205 \text{ ч речи} \div 40 = 5.1$; диаризация: $205 \div 15 = 13.7$; LLM: $650 \text{ разговоров} \div 180 = 3.6$; итого **22.4 GPU-ч/сутки** — покрывается почасовой арендой одной 4090 (соответствие «число параллельных обработчиков»: днём 2 GPU-эквивалента, ночью 1). Пиковый час порождает 3.85 GPU-ч работы → при двух активных GPU разбирается за ~2 часа — внутри SLA (гл. 6.5). На 1000 менеджеров: 224 GPU-ч/сутки — **парк 10–12 × 4090** (консервативно) или 4–5 (оптимистично), с автоскейлом почасовых под субботы.

8.3. Хранение

На менеджера: $64.3 \text{ ч/мес} \times 10.5 \text{ МБ/ч} \approx 0.66 \text{ ГБ/мес}$ нового аудио. Ретенция 6 мес (юридическая рекомендация, гл. 10): steady-state 4 ГБ/менеджера. Первый месяц — standard (2.3 ₽/ГБ), остальное — cold (1.1 ₽/ГБ):

	100 менеджеров	1000 менеджеров
Новое аудио в месяц	66 ГБ	663 ГБ
Steady-state (6 мес)	398 ГБ	3 977 ГБ
Стоимость в месяц	~520 ₽	~5 170 ₽

Хранение — статистическая погрешность бюджета (<1%): экономить на ретенции незачем, ограничивает её юридика, а не деньги. Транскрипты и разборы (~1 МБ на менеджера в месяц в PG)

— пренебрежимо.

8.4. Месячный OPEX

Статья, Р/мес	100 менеджеров		1000 менеджеров	
	конс.	опт.	конс.	опт.
GPU (аренда: часы × 82.76 Р либо выделенные 29–57 т.Р/мес — оптимум по масштабу)	56 300	20 900	563 100	131 800
Хранение S3	520	520	5 170	5 170
Бэкенд-фикс: BM ×2–3, Managed PG, мониторинг	35 000	35 000	120 000	120 000
LTE площадок (×5 / ×50)	5 000	5 000	50 000	50 000
Итого, Р	96 800	61 400	738 300	307 000
На менеджера, \$/мес (бюджет \$15)	11.7	7.4	8.9	3.7

Комментарии. (1) Крупнейшая статья на малом масштабе — фиксированный бэкенд: юнит-экономика улучшается с ростом сама. (2) LLM-разбор в таблице «бесплатен»: он выполняется в купленные GPU-часы (3.6 ч/сутки из 22.4); альтернатива — GigaChat Pro batch API (3.38 Р/разговор = 48 300 Р/мес на 100 менеджеров = +\$5.8/менеджера) — законная запаска, если свой LLM-контур захочется отложить, бюджет всё ещё сходится (\$17.5 — на грани, поэтому запаска, а не план). (3) Почему не API-распознавание: SpeechKit/SaluteSpeech ≈ 36 Р/час аудио × 64.3 ч = **2 315 Р = \$28/мес на менеджера за один только ASR** — вдвое выше всего бюджета; это решение продиктовано арифметикой, а не вкусом.

8.5. Чувствительность

Фактор	Диапазон	Эффект на \$/менеджера (100 mgr)
RTFx диаризации (главная неопределённость)	15 → 50	–2.9
Цена GPU-часа (immers → HOSTKEY-класс)	82.76 → 40 Р	–3.4
Разговоров/смена	6.5 → 8	+1.6
Курс Р/\$	83 → 100	–2.0 (расходы рублёвые, бюджет долларовый)
Доля речи после VAD	0.70 → 0.85	+1.2

Худший разумный стек факторов (8 разговоров/смена + 85% речи одновременно: ~\$14.8) подходит к бюджету впритык — и лечится любым из трёх рычагов: тюнинг диаризации (батчинг эмбедингов — известные 3–5× у ruannote), скидки предоплаты GPU (10–50% у immers), выделенные серверы при стабильной загрузке. Запас прочности бюджета оцениваем как достаточный.

8.6. CAPEX (сводно; вывод BOM — гл. 3)

100 менеджеров: бейдж \$52 + ЗИП 10% + док \$12 + сеть площадки \$29 = **\$98** (бюджет \$100). 1000: **\$75**. Парк целиком: \$9 845 и \$75 350 соответственно — примечательно, что весь CAPEX программы на 100 менеджеров меньше месячного фонда оплаты труда двух менеджеров.


9. Этап 2: подсказки в реальном времени

9.1. Что меняется в системе

Этап 1 спроектирован так, чтобы этап 2 был включением, а не перестройкой: бейдж уже кодирует Orus кадрами по 20 мс — добавляется их стриминг по Wi-Fi на шлюз (параллельно записи на SD; энергетика — гл. 9.5); шлюз уже стоит на площадке — на нём поднимается быстрый контур; в облаке добавляется пул стриминговых ASR-воркеров. Запись и батч-разбор этапа 1 продолжают работать без изменений — стриминг лишь дополнительный потребитель тех же кадров.

9.2. Бюджет задержки

Этап 2: бюджет задержки подсказки (от слов клиента до вибрации на часах)



Пауза в реплике клиента (600 мс тишины) финализирует фразу — подсказка приходит в естественной паузе, а не перебивает.

Быстрый путь (без LLM): триггер по ключевым фразам на шлюзе $\rightarrow$ готовый шаблон ≈ 0.7 с.

Деградация: нет интернета $\rightarrow$ работает только быстрый путь; нет Wi-Fi до шлюза $\rightarrow$ подсказок нет, запись продолжается.

Рис. 6. Водопад задержки LLM-подсказки; быстрый путь на шлюзе — 0.7 с.

Звено	Задержка	Обоснование
Захват + кадрирование Orus + Wi-Fi до шлюза	~ 120 мс	кадр 20 мс, джиттер-буфер 60–80 мс на потери Wi-Fi
Шлюз $\rightarrow$ облако	~ 80 мс	LTE RTT 40–70 мс типично для РФ-сетей
Стриминговый ASR (T-one)	~ 330 мс partial	документированная эмиссия: чанк 300 мс; финализация фразы 1–1.2 с (порог тишины 600 мс)
Детектор триггера	~ 50 мс	правила + лёгкий классификатор по скользящему окну транскрипта
Генерация подсказки LLM 8B	~ 800 мс	подсказка ≤ 30 токенов; TTFT+декод на выделенном инференсе (QVikhr-3-8B класс)
Доставка на телефон/часы	~ 400 мс	WebSocket на телефон по Wi-Fi/LTE + зеркалирование уведомления на часы
Итого LLM-путь	≈ 1.8 с (разброс 1.5–3 с)	цель ≤ 3 с: подсказка успевает в естественную паузу диалога

Быстрый путь (шлюз, без облака)	≈0.7 с	T-one на CPU шлюза + библиотека готовых шаблонов («упомянут трейд-ин → напомнить про акцию оценки»)
--	---------------	---

Почему это честные цифры: единственное неочевидное звено — стриминговый ASR — взято из открытого бенчмарка T-one (Apache 2.0, обучен на 80 тыс. ч русской телефонии, WER 8.6% на колл-центре — лучший класс для нашего звука). Ключевое продуктивное решение, экономящее секунды: подсказка не «суфлёр в ухо посреди фразы», а короткий nudge в паузе — финализация фразы клиента (600 мс тишины) сама попадает в момент, когда менеджер может взглянуть на часы.

9.3. Куда доставлять подсказку

Канал	Плюсы/минусы	Вердикт
Часы (Redmi Watch 5 Active, 2 699 ₽)	вибро + 5–7 слов; взгляд на часы социально нейтрален; свой SDK не нужен — зеркалирование уведомлений телефона	основной
Телефон менеджера (приложение)	полный текст, история подсказок; телефон в руках при клиенте — плохо	носитель канала для часов + разбор после
Наушник (~600 ₽)	голосовая подсказка незаметна... и слышна клиенту ощущением «менеджеру суфлируют»; выглядит как неуважение	отвергнут для шоурума; опция для колл-центра

9.4. Что подсказываем (и чего не обещаем)

Реалистичные и полезные классы подсказок: чек-лист этапа («не спросил про трейд-ин»), реакция на триггер-фразы («дорого» → напомнить про рассрочку/остаточный платёж; «подумаю» → предложить закрепить тест-драйв), комплаенс («озвучь обязательное уведомление о записи»), сигнал РОПу «подойди, сделка греется/горит» (менеджер не справляется — старший включается вживую: организационная подсказка часто ценнее текстовой). Не обещаем: полного суфлёра, генерации аргументации на лету в ухо, анализа эмоций как продукта (сырой сигнал тона — максимум как второстепенная фишка РОПу). Причина — не техника, а UX: менеджер, читающий простыню с часов, продаёт хуже, чем менеджер без подсказок.

9.5. Нагрузка и стоимость этапа 2

- **Бейдж:** стриминг добавляет Wi-Fi TX почти постоянно → среднее потребление растёт с ~60 до ~110–130 мА; батарея 2000 мА·ч держит смену на пределе (11 ч × 120 мА = 1320 мА·ч < 1600 доступных с деградацией). Решения: стримить только при детекции дальней речи (разговор, а не хождение), в остальное время — heartbeat; при батарее <30% — стриминг off, запись остаётся. Запас в BOM на ревизию В: посадочное место под 2500 мА·ч.
- **Стриминговый ASR-пул:** пиковый час 1000 менеджеров = 600 одновременных потоков; T-one на TensorRT держит тысячи потоков на одной A100 (бенчмарк: 7 833 потока) — хватает 1 A100 (212–316 ₽/ч только в рабочие часы ≈ 25–40 тыс. ₽/мес на всю сеть из 1000) либо 2–3 × 4090. На 100 менеджеров — стриминг-контур живёт на тех же 4090, что и батч.
- **LLM-подсказки:** 8B-модель, ~1 вызов на 2–3 минуты активного разговора, ≤30 токенов ответа → одна 4090 обслуживает ~200+ одновременных разговоров; +1 GPU на 100 менеджеров с запасом.

- **Итого +\$2–3/менеджера/мес** к OPEX этапа 1 (GPU стриминга + LLM + часы ~2 700 ₽ единовременно на менеджера, если часов ещё нет). Бюджет \$15 выдерживает оба этапа в консервативном сценарии ($\$11.7 + \$2.5 \approx \$14.2$); часы в CAPEX выходят за \$100 на ~\$33 @100 — фиксируем как осознанное превышение этапа 2 (альтернатива — телефон без часов, \$0).

9.6. Деградация этапа 2

Нет облака (LTE лёг) → быстрый путь на шлюзе продолжает давать шаблонные подсказки (0.7 с). Нет Wi-Fi до шлюза (менеджер на тест-драйве) → подсказок нет, запись продолжается, батч-разбор не страдает. Этап 2 — надстройка, отказ которой никогда не трогает этап 1.

10. Надёжность, безопасность, право

10.1. Отказы: что ломается и что происходит

Отказ	Поведение системы	Что теряем
Wi-Fi площадки лёг	бейджи копят на SD (недели ёмкости); выгрузка при восстановлении или в доке	ничего; задержка разбора
LTE и провод легли одновременно	шлюз копит 7 дней; бейджи выгружаются в него штатно	ничего; задержка
Шлюз умер	бейджи копят на SD; замена шлюза — типовой мини-ПК, конфиг из облака, 1 час	ничего; задержка + этап 2 на площадке offline
Бейдж утоплен/ разбит до выгрузки	—	невыгруженные разговоры (обычно ≤ 1 смены) — единственный сценарий потери данных
Облако недоступно	шлюзы копят; пайплайн догоняет после восстановления (парк GPU переразмерен к среднему в 2–3×)	ничего; SLA-задержка
GPU-провайдер деградировал	переезд воркеров на почасовые у второго провайдера (образы провайдеро- независимы)	часы задержки разбора
Менеджер «забывает» бейдж	телеметрия: % записанных смен падает → виден РОПу	данные этого менеджера; лечится процессом (гл. 11), а не техникой

10.2. Безопасность

- **Устройство:** ключ в eFuse, сегменты AES-GCM — украденный бейдж/карта не читаются; mTLS-идентичность на устройство, отзыв сертификата при пропаже; подписанные OTA.
- **Транспорт:** WPA3 на своей AP, WireGuard шлюз→облако; бейджи не видят интернет вообще (VLAN только до шлюза).
- **Облако:** шифрование S3 at-rest, доступ к аудио — только через сервис выдачи с RBAC и журналированием каждого прослушивания (кто, что, когда — журнал виден СБ); прод-доступ инженеров — по break-glass процедуре.
- **Минимизация:** PII-маскирование транскриптов вторым проходом (имена, телефоны, паспорта); обучающие подборки — только маскированные; фрагменты со спецкатегориями (здоровье, семья — клиент случайно рассказал) детектируются LLM и вырезаются из хранения (юридическое требование, см. ниже).

10.3. Правовая конструкция (РФ, август 2026)

Проверено по первоисточникам и разъяснениям (список — прил. Б); финальный пакет документов подлежит валидации практикующим юристом по ПДн.

- **Запись — персональные данные, но не биометрия**, пока голос не используется для установления личности (ст. 11 152-ФЗ: оба условия должны выполняться). Поэтому в системе —

архитектурный запрет voice-ID: роли определяются геометрией микрофонов (гл. 4), голосовые профили не строятся и не хранятся. Нарушение этой границы переводит систему в режим биометрии: письменные согласия, УЗ-1/УЗ-2, штраф за утечку 15–20 млн ₽.

- **Основание обработки клиентов** — связка: заметные таблички «ведётся аудио- и видеозапись» + устное уведомление в начале предметного разговора (пункт скрипта менеджера, контролируется самим же разбором) + **явное согласие отдельным документом** на этапе анкеты/записи на тест-драйв (с 01.09.2025 согласие — только обособленная форма) + п. 5 ч. 1 ст. 6 152-ФЗ (преддоговорные отношения) для реальных покупателей. «Зашёл поглазеть» без последующего контакта — разговор не персонализируется: остаётся анонимной статистикой без связки с CRM, аудио удаляется по короткому TTL (30 дней).
- **Сотрудники:** ЛНА «о контроле качества обслуживания» (цели: контроль качества, обучение, разбор споров; доступы; сроки), ознакомление под подпись, доп. соглашения; использование записей только в заявленных целях — дисциплинарка на записях при цели «обучение» юридически уязвима, это же условие приживаемости (гл. 11). Арбитражная практика запись переговоров сотрудников с клиентами при ЛНА поддерживает.
- **Локализация (ч. 5 ст. 18):** весь конвейер в РФ; зарубежные ASR/LLM API исключены архитектурно (штраф 1–6 млн ₽, повторно 6–18 млн). Облако — сегмент «152-ФЗ» (УЗ-3 целевой уровень по ПП 1119), договор поручения обработки с провайдером.
- **Оператор:** уведомление РКН (обновить: цели, аудио, облако), политика, ответственный, модель угроз, меры приказа ФСТЭК №21, регламент утечек 24 ч/72 ч. Лицензии ФСТЭК не требуется (обрабатываем собственные ПДн).
- **Ретенция:** аудио 6 мес (авто-TTL в S3), маскированные транскрипты 24 мес, разборы/агрегаты — без ПДн, бессрочно. Права субъектов: выдача/удаление по запросу — реализуется штатным API (данные и так связаны с клиентом в CRM).
- **Главный риск — утечка массива записей:** > 1 000 субъектов → 3–5 млн ₽, повторно — оборотный штраф 1–3% выручки (от 20 млн). Дизайн минимизации: компактный периметр аудио (один сервис выдачи), маскирование, вырезание спецкатегорий, короткая ретенция, журналирование доступа. Тайна связи (126-ФЗ) к живым разговорам не применяется — подтверждено; при добавлении записи телефонии потребуется отдельный контур.

11. Внедрение и человеческий фактор

11.1. Анти-саботаж как проектное требование

«Менеджеры не технари и саботируют всё, что усложняет им день» — главное небюджетное ограничение ТЗ. Ответ на него распределён по всей системе, здесь сведён воедино:

- **Ноль действий для записи:** снял бейдж с дока — работает; поставил — выгрузился и заряжается. Бейдж заменяет обычный именной — не «дополнительный предмет».
- **Личная польза раньше контроля:** автолиды и автозадачи из разговора экономят менеджеру ввод в CRM; «мой разбор дня» в Telegram помогает не забыть обещанное клиенту; подтверждение сопоставлений — 1 минута.
- **Политика «запись для обучения, не для наказаний»**, закреплённая в ЛНА и публично объявленная: без неё бейджи начнут «тонуть в кофе». Дисциплинарные решения на записях, кроме грубых нарушений (хамство, обман клиента), — запрещены политикой; это совпадает с юридической рекомендацией (гл. 10).
- **Кнопка «пауза 10 минут»** — легальный клапан приватности; злоупотребление видно в статистике полноты, вопрос решает РОП процессно.
- **Прозрачная метрика приживаемости:** % записанных смен по менеджеру и площадке — на дашборде РОПа; цель $\geq 85\%$ к концу пилота.

11.2. Пилот (одна площадка, 8 недель)

Недели	Работы	Выходной критерий
1–2	монтаж шлюза/AP/доков; 5 менеджеров-волонтёров с OEM-бейджами (план Б, гл. 3.6); юрпакет: таблички, ЛНА, формы согласий	записи идут, выгрузка стабильна
3–4	включение пайплайна; сбор золотого набора (50 разговоров с ручной разметкой); калибровка сегментации и матчинга	WER на канале менеджера $\leq 12\%$; $\geq 60\%$ авто-сопоставлений
5–6	карточки в CRM и дашборд РОПу; Telegram-бот менеджерам; расширение до 20 менеджеров, замена на свои бейджи (EVT-партия)	$\geq 80\%$ записанных смен; РОП пользуется дашбордом еженедельно (факт логина и разборов)
7–8	прогон недельного цикла обучения: паттерн ошибок → CoachingTask → контроль динамики; замер юнит-экономики факта	$\geq 75\%$ авто-сопоставлений после шага Б; OPEX-факт $\leq \$15$; менеджеры-волонтёры рекомендуют систему коллегам (опрос)

Стоп-критерии пилота (честные): полнота записи $< 60\%$ при исправном железе (саботаж не лечится UX'ом — вопрос к политике мотивации), WER канала менеджера $> 20\%$ (акустическая гипотеза не подтвердилась — пересмотр микрофонной схемы), авто-сопоставление $< 40\%$ (дисциплина визитов в CRM нулевая — сначала процессный проект в CRM, потом аналитика).

11.3. Роллаут на 5 площадок и рост до 1000

Волнами по 1–2 площадки в 2 недели: монтаж — 1 день (шлюз+АР+доки), обучение РОПа — 2 часа, менеджерам — 15-минутный стендап («бейдж вместо вашего обычного, вот док, вот бот»). Рост до 1000 менеджеров не меняет архитектуру (гл. 8): парк GPU 10–12 карт, РСВА-партия 1000 бейджей (себестоимость падает до \$31), команда сопровождения — 1 инженер флота на ~300 устройств + саппорт-линия в Telegram. Узкое место масштабирования — не техника, а онбординг РОПов: дашборд без привычки им пользоваться — мебель; поэтому в роллаут-план заложен еженедельный 30-минутный разбор с каждым РОПом первые 4 недели площадки.

12. Почему это будет полезно: модель ценности

12.1. Что руководство получает впервые

Сегодня о содержании 650 разговоров в день на сеть известно ровно то, что менеджеры записали в CRM — то есть почти ничего, и с систематическим искажением («клиент думает» вместо «я не отработал возражение»). Система делает разговор наблюдаемой единицей управления:

- **Воронка по фактическим этапам разговора**, а не по отметкам менеджера: где реально теряются сделки (не дошли до тест-драйва? споткнулись о трейд-ин? отпустили «подумать» без следующего шага?).
- **Карта возражений**: топ-возражения недели × доля отработанных × у кого получается (их формулировки — в обучение остальным: библиотека лучших ответов собирается из собственных звёзд, а не из книжек).
- **Таргетное обучение**: CoachingTask по паттерну ошибок конкретного менеджера с примерами из его же разговоров; прогресс измерим по следующим разговорам. Онбординг новичка: библиотека эталонных разговоров + разбор его первых диалогов — выход на план быстрее.
- **Ранние сигналы по сделкам**: «горячий клиент без следующего шага», «обещание не выполнено», «конкурент упомянут трижды» — РОП вмешивается, пока сделка жива.
- **Голос клиента для маркетинга**: что спрашивают, что сравнивают, какие акции упоминают — агрегированно и без ПДн.

12.2. Расчёт окупаемости (консервативный)

Площадка 20 менеджеров: ~2 860 разговоров-визитов в месяц; при конверсии шоурум→сделка 15% это ~430 продаж... — для консервативности возьмём официальную статистику хуже: пусть уникальных клиентов-визитов 1 200/мес (часть разговоров — повторные), конверсия 15% = 180 продаж/мес, маржа 80 тыс. ₽ с автомобиля (нижний край для дилера с учётом допов/кредита/трейдинга).

	Значение
Стоимость системы на площадку (этап 1, конс.)	$20 \times \$11.7 \times 83 \approx$ 19 400 ₽/мес
Безубыточность	$19\,400 \div 80\,000 =$ 0.25 автомобиля в месяц , т.е. +0.02 п.п. к конверсии (0.25/1200 визитов)
Реалистичный эффект: +1 п.п. конверсии (12 доп. продаж/мес)	+960 тыс. ₽ маржи/мес на площадку → ROI $\approx$ 50×
Только «спасённые» сделки по ранним сигналам (2/мес)	+160 тыс. ₽/мес → ROI $\approx$ 8× даже без роста конверсии

Отраслевые данные по речевой аналитике телефонии дают +5–15% к конверсии обработанных контактов; мы сознательно считаем окупаемость от +0.02 п.п. — порога, который проходится при любом различимом эффекте вообще. Асимметрия риска: даунсайд — \$98 CAPEX и \$11.7/мес на менеджера; апсайд — единицы процентов конверсии на марже автомобилей.

12.3. Проверяемость эффекта

Эффект меряется по дизайну, а не по ощущениям: роллаут волнами даёт естественный A/B (площадки с системой vs без), метрики фиксируются до старта (конверсия, средний чек допов, скорость прохождения этапов, выполнение обещаний клиентам). Отчёт «эффект за квартал» — часть продукта (дашборд руководства сети), потому что покупает систему не РОП, а владелец сети — и ему нужен ответ «сколько это принесло», а не «сколько разговоров записано».

Приложение А. ВОМ бейджа: партномера

Компонент	Партномер	Примечание
SoC-модуль	ESP32-S3-WROOM-1-N16R8	16 МБ flash / 8 МБ PSRAM; LCSC C2913202
Микрофоны ×2	TDK InvenSense ICS-43434	I2S 24 бит, SNR 64 дБА, AOP 120 дБ SPL; LCSC C5656610
Зарядка + power-path	TI BQ24074RGTR	работа при зарядке в доке; LCSC C54313
Fuel gauge	Maxim MAX17048G+T10	% батареи в телеметрию; LCSC C2682616
LDO 3.3 В	ME6211C33 (500 мА, IQ 60 мкА)	LCSC C82942
Аккумулятор	LiPo 103450, 2000 мА·ч, с PCM	типоразмер 10×34×50 мм
Накопитель	microSD 32 ГБ Class 10 + push-push держатель	промышленная серия — опция для −20...+85 °С
Индикация	WS2812B-2020	один RGB-светодиод состояния
Разъёмы	USB Type-C 16P (заряд/сервис), пого-пады ×4	док: 5 В + GND + 2 резерва (UART для диагностики)
Прошивка	ESP-IDF 5.x + libopus fixed-point	Opus 16 кГц mono 24 кбит/с, complexity 0–2

Приложение Б. Цены и бенчмарки: источники (проверено 17.08.2026)

Факт	Значение	Источник
Выделенный сервер RTX 4090	от 56 900 ₽/мес	selectel.ru/services/gpu (офиц. прайс)
RTX 4090 почасово	82.76 ₽/ч (59 587 ₽/мес)	immers.cloud/gpu/4090 (офиц.)
VPS с RTX 4090	~29 000 ₽/мес	обзор aillist.ru 07.2026 (HOSTKEY)
Облачный L4 24 ГБ	от 69.88 ₽/ч	selectel.ru/services/gpu
A100 80 ГБ в РФ	212–317 ₽/ч	immers.cloud ; cloud.ru тарифы 11.08.2026
S3 standard / cold	2.28–2.38 / 1.09–1.3 ₽/ГБ·мес	прайс VK Cloud с 12.01.2026; cnews market (Selectel); docs Яндекса
Managed PostgreSQL / BM 4 vCPU	от 5 502 / от 5 838 ₽/мес	toolfox.ru 03.2026 (Яндекс Облако)
WER GigaAM-v3 vs Whisper-v3 (телефония)	17.4 vs 27.4; Golos Farfield 3.9 vs 16.4	github.com/salute-developers/GigaAM , evaluation.md (офиц.)
Независимый бенчмарк русского ASR	GigaAM2 8.42% avg — лучший открытый	alphacephei.com/nsh/2025/04/18/russian-models.html
Скорость GigaAM (GPU, ONNX)	RTF 0.033 (≈30× поток)	habr.com/ru/articles/1042574

faster-whisper turbo batched	41× на L4; 70–100× на 4090	e2enetworks.com бенчмарк L4 2026; SYSTRAN/faster-whisper
T-one стриминг	чанк 300 мс, эмиссия ~330 мс, пайплайн 1–1.2 с; WER колл-центр 8.63%	github.com/voicekit-team/T-one; habr Т-Банка 07.2025
pyannote community-1	DER: AMI 17.0, DIHARD-3 20.2; exclusive-режим	huggingface.co/pyannote/speaker-diarization-community-1
Silero VAD	MIT, <1 мс/чанк на CPU	github.com/snakers4/silero-vad
SpeechKit / SaluteSpeech (ASR API)	≈36 Р/ч; у Сбера мин. платёж 15 000 Р/мес	developers.sber.ru тарифы (офици.); своды по SpeechKit
GigaChat API (юрлица, 15.07.2026)	Lite 65/32.5, Pro 500/250, Max 650/325 Р/1М ток. (синхр./batch)	developers.sber.ru/docs/ru/gigachat/tariffs/legal-tariffs
T-Pro 2.0 (32B, русский)	файнтюн Qwen3-32B, гибридный резонинг	habr.com/ru/companies/tbank/articles/928956
vLLM 32B AWQ на 4090	~65 ток/с decode; ≈180–300 разборов/GPU-ч	gigagpu.com, databasemart.com бенчмарки 2026
ESP32-S3, Opus 16 кГц	4.9× RT @ c0 (fixed-point)	components.espressif.com / esp8266 micro-opus benchmark
Потребление ESP32-S3	modem-sleep 33–81 мА; Wi-Fi TX до 283 мА	даташит ESP32-S3 v2.2, табл. 5-7...5-10
Компоненты бейджа	см. гл. 3.2	живые тарифные сетки LCSC, 17.08.2026
Plaud NotePin / HiDock H1	\$159 / \$269	plaud.ai, hidock.com (офици. магазины)
Сеть площадки	N100 26 900 Р; hAP ax ² 12 490 Р; Keenetic 4G ~9 000 Р; SIM 700–1500 Р/мес	nezz.ru/DNS; mikrotik.ru; Я.Маркет; media.mts.ru
Правовая база	152-ФЗ (ст. 6, 9, 11, 18, 21, 22), КоАП 13.11 (ред. 420-ФЗ), 233-ФЗ, ПП 1119, приказ ФСТЭК №21, ВС РФ 35-КГ16-18	consultant.ru, garant.ru, разъяснения РКН; детальный разбор — гл. 10
Курс	82.6–83 Р/\$	ЦБ РФ, середина августа 2026

Пометка о методе: цены собирались по официальным страницам провайдеров и производителей; там, где официальная страница недоступна роботу (капча у Яндекс), значение сверено по двум независимым вторичным источникам и помечено в тексте как оценка.

Приложение В. Схема LLM-разбора (сокращённо)

```
{
  "conversation_id": "...",
  "schema_version": "1.3",
  "summary": "абзац: кто, что хотел, чем закончилось",
  "deal_stage_reached": "contact|needs|presentation|test_drive|objections|pricing|commitment",
  "outcome": "next_step_agreed|thinking|lost|purchased|no_sale_intent",
  "next_step": {"what": "...", "when": "2026-08-21", "confirmed_by_client": true},
  "objections": [
```

```

    {"type": "price|trade_in|credit|competitor|trust|timing|other",
      "quote_t0": 1082.4, "text": "дороже, чем в X",
      "handled": true, "handling_quality": 1..5, "handling_quote_t0": 1104.0}
  ],
  "commitments_by_manager": [{"what": "КП по кредиту", "due": "...", "t0": 811.2}],
  "checklist": [{"item": "спросил про трейд-ин", "done": false}],
  "scores": {"needs_discovery": 1..5, "presentation": 1..5, "objection_handling": 1..5,
    "closing": 1..5, "compliance_notice_given": true},
  "risk_flags": ["hot_client_no_next_step", "competitor_mentioned_3x"],
  "entities_for_matching": {"client_name": "...", "phone_last4": "...", "car_model": "...",
    "trade_in_model": "..."},
  "special_category_spans": [{"t0": 51.0, "t1": 58.5, "reason": "health"}] // к вырезанию
}

```

Каждый содержательный факт несёт таймкод-якорь (t0) — проверка по аудио в один клик. Поле `special_category_spans` обслуживает юридическое требование гл. 10.